

基于卷积神经网络的刀具磨损在线监测

曹大理, 孙惠斌, 张纪铎, 莫 蓉

(西北工业大学 航空发动机高性能制造工业和信息化部重点实验室, 陕西 西安 710072)

摘要:为了提高刀具磨损在线监测的精度和泛化性能,提出一种基于卷积神经网络的刀具磨损量在线监测模型。利用时域传感器信号对刀具磨损量进行定量分析,避免数据预处理带来的信息丢失;采用深度网络自适应地提取特征,取代传统的人工特征提取过程,并通过加深网络进一步挖掘信号中隐藏的微小特征。实验结果表明,该模型对刀具后刀面磨损量监测效果较好,可以有效避免人为特征提取的局限,精度和泛化性都有一定程度的提高。与相关研究的对比也证实了其可行性和有效性。

关键词:刀具状态监测;刀具磨损量;时域传感器信号;卷积神经网络;特征提取

中图分类号:TP391.7 **文献标识码:**A

In-process tool condition monitoring based on convolution neural network

CAO Dali, SUN Huibin, ZHANG Jiduo, MO Rong

(Key Laboratory of High Performance Manufacturing for Aero Engine, Ministry of Industry and Information Technology, Northwestern Polytechnical University, Xi'an 710072, China)

Abstract: To improve the accuracy and generalization, a tool condition monitoring approach is proposed based on convolutional neural network(CNN). To prevent the loss of signal information caused by the data preprocessing, signals in time domain were used to analyze tool wear condition quantitatively. Instead of manually extracting features from signals, an adaptive method is developed by using deep network. In order to mine tiny features, deeper neural network is used. The experiment study verifies the approach's excellent performance. Both accuracy and generalization are improved, when the limitation of manual feature extraction is avoided. The comparison with relevant studies also validates its feasibility and efficiency.

Keywords: tool condition monitoring; tool wear condition; signals in time domain; convolution neural network; feature extraction

0 引言

随着智能制造技术的发展,工艺系统需要进一步提高主动感知、自主决策的能力。为此,刀具状态监测(Tool Condition Monitoring, TCM)再次成为加工领域的研究热点^[1]。由于传统在线监测方式人为观察主观性强、仪器测量遮挡严重^[2],间接监测方式被广泛采用,主要利用传感器采集加工过程中的切削力^[3]、振动^[4]、声发射信号^[5]经过预处理和敏感

特征提取后,采用模糊推理系统^[6]、隐马尔可夫模型^[7]、模糊神经网络^[8]、支持向量机^[9]、贝叶斯网络^[10]等机器学习模型对刀具磨损量进行监测。该类方法受制于特征提取的质量。为了提取到与刀具磨损状态强相关的特征,研究人员不仅要善于观察和发现,还需要一定的技巧和经验,且提取到的特征可解释性和通用性弱,不能排除更敏感的特征已被遗漏。

近几年,以自编码网络及卷积神经网络为代表

收稿日期:2018-04-09;修订日期:2018-10-15。Received 09 Apr. 2018;accepted 15 Oct. 2018.

基金项目:国家自然科学基金资助项目(51875475);陕西省重点研发计划资助项目(2018ZDXM-GY-068)。**Foundation items:** Project supported by the National Natural Science Foundation, China(No. 51875475), and the Natural Science Basic Research Plan in Shaanxi Province, China(No. 2018ZDXM-GY-068).

的深度神经网络模型逐渐被应用于刀具磨损状态监测。林杨等^[11]利用自编码降噪机对刀具状态进行分类。张存吉等^[12]利用经典卷积神经网络,根据加工信号频谱图对刀具磨损状态进行分类。以上模型性能已经远超传统“特征提取+机器学习模型”,但是,此类模型还需进一步完善。首先,对于自编码网络来说,由于没有对整体模型进行全局优化,网络层数过高后可能会导致模型失效,而利用卷积神经网络构建的模型依赖于卷积操作对高维特征的提取,少量的卷积操作无法对刀具磨损量进行精确预测。其次,目前此类研究多用于刀具磨损状态的分类,属于定性监测,用于磨损状态回归和定量监测较少。最后,以上模型都将信号转换到频域或时频域进行分析,可能造成一定程度上信息的损失。

因此,本文提出一种基于卷积神经网络(Convolutional Neural Network, CNN)的刀具磨损在线监测方法,从原始的时域信号中自适应地提取刀具加工信号特征,防止数据预处理与人工提取特征可能带来的信息丢失,利用密集连接的方式搭建层数更深的网络,建立对当前时刻刀具磨损量的监测模型,进一步挖掘信号中隐藏的微小特征,划分训练集与验证集,对模型进行训练和验证,以防止过拟合现象的发生,简化模型并进一步保证其精度和泛化性能。

1 基于 CNN 的刀具磨损在线监测模型

基于 CNN 的刀具磨损监测模型如图 1 所示。数控加工中心加工工件过程中利用传感器收集信号,模型输入为某一切削行程中传感器采集到的刀具加工信号(包括 F_x, F_y, F_z 力信号, a_x, a_y, a_z 加速度信号,及声发射信号),输出为后刀面磨损量。原始信号将 x, y, z 方向上的切削力, x, y, z 方向的加速度,以及声发射共 7 种时域信号经二次采样裁剪为 5 000 个采样点组合成为 (5 000, 7) 的张量。DenseNet 初始状态下连接权重未确定,需利用历史数据中训练样本的预测值与真实值之间的均方误差作为目标函数训练模型,确定各层连接权重,得到最优监测模型。神经网络架构采用训练后的 DenseNet 连接结构卷积神经网络,输入当前行程采集到的数据张量先经过卷积层和规范层处理信号数据,再经过 9 个密集连接块(Dense block),在激活函数的作用下连接平均池化层和全连接层,输出后刀面磨损量。其中,密集连接块包括 4 次卷积操作

和 1 次池化操作跨层连接,卷积核生长因子(growth rate)定为 12,用来表示每个密集连接块中每层输出的特征个数。

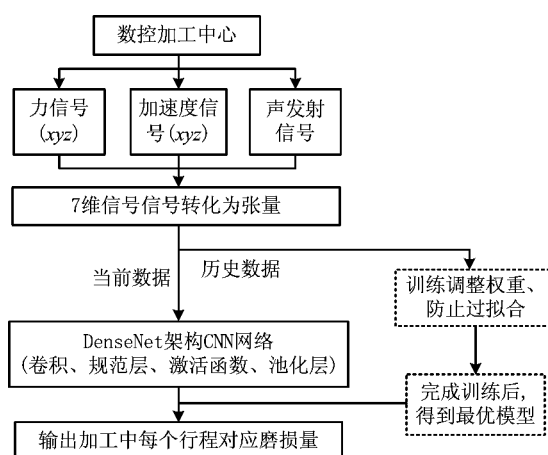


图1 基于CNN的刀具磨损量监测模型

为了提高精度和泛化性能,需要尽可能加深模型的结构,使模型挖掘加工信号中隐藏的微小信息、避免梯度弥散;模型中的运算要便于自适应特征提取;模型的训练要避免过拟合现象的发生。下面将对这 3 项关键技术的实现分别进行论述。

2 关键技术

2.1 DenseNet 网络的构建

2006 年 Hinton 等提出了深度信念网络^[13],通过组合低层特征形成更抽象的高层特征,即利用多个隐含层从高维原始数据中挖掘出隐含的微小信息。本文结合深度学习和刀具磨损规律的自身特点,将加工过程中采集到的数字信号视为一维图像,利用在图像识别领域有显著效果的 CNN 网络建立信号与磨损量之间的映射关系,利用卷积和池化操作自适应地提取特征参数,减少冗余信息,使得模型具有更高的精度和泛化性能^[13]。为了避免训练过程中的梯度弥散问题,采用 DenseNet 连接架构,在加深网络的同时促进高维特征和低维特征相互融合。

密集连接块(Dense block)的结构如图 2 所示。在传统卷积神经网络中,层数与连接数一一对应。在 DenseNet 架构中, l 层会产生 $\frac{l(l+1)}{2}$ 个连接,即每一层的输入来自前面所有层的输出,在图 2 中, X_0 为密集连接块的初始输入,则模型接收层 H_1 的输入为 X_0 , H_2 层的输入是 X_0 和 X_1 , H_3 层的输入

是 X_0 、 X_1 和 X_2 。第 l 层的输出结果如式(1)所示:

$$X_l = H_l([X_0, X_1, \dots, X_{l-1}])。 \quad (1)$$

这样的连接方式使得每一层都直接连接输入信

息和梯度信息,充分利用每层输出的特征,从而减轻梯度弥散现象^[14]。




图2 Dense block结构图

为保证密集连接块中输入张量形状不变,在每个密集连接块后连接传导块(Transition block),设置传导块中的卷积、池化操作步长大于1,以减小神经网络中传导张量的大小,减小连接权重数量。

DenseNet 网络结构图如图3所示,为保证模型输入不会因数据预处理而产生不必要的信息损失,网络输入为(5000,7)的时域信号张量,经过卷积

(Conv1D)、归一化(BN)、激活函数(ReLu)、池化(Pooling1D)等操作提取高维信息。其中,Dense block 中信号张量大小不变,维度增加,Transition block 中卷积和池化操作每次将张量大小缩减为一半。经过9个密集连接块及8个传导块后,张量大小变为(1,244),连接到全连接层(Dense),通过不同权重线性求和,输出当前时刻的刀具磨损量。




图3 DenseNet网络结构图

2.2 自适应特征提取与选择

特征提取是传统机器学习方法的难点。本文使

用卷积操作自适应地提取加工信号中的特征,基本原理如图4所示。




图4 一维卷积示意图

卷积层(Convolutional layer)主要是通过一维卷积运算的方式来将每一维的时域信号进行邻域滤波。为了提取特征,卷积神经网络使用了如式(2)的卷积运算替代一般的矩阵乘法运算。

$$c(t) = x \times w = \sum_{p=0}^P x[p] \cdot w[q-p]。 \quad (2)$$

式(2)对输入采样信号 x 与不同的卷积核 w 进行卷

积运算, p 和 q 分别代表采样总数和卷积核大小,得到输出 $c(t)$ 使信号的特征得到凸显。在图4中,通过卷积核中 $w[2]$ 的不同,使采样信号中的 $x[3]$ 在输出 $c[2]$ 中占有更大比重。该层是基于CNN的刀具磨损监测模型的核心,是其超越传统刀具磨损特征提取的关键手段。

因此,输入(5000,7)的原始加工时域信号张量,

经过卷积与池化运算后,最终输入全连接层(Dense)的张量为(1,244)的高维特征,即卷积层最终自适应提取到的刀具磨损特征。选取不同维度的特征,利用皮尔逊系数(Pearson Correlation)及互信息和最大信息系数(Mutual information and maximal information coefficient)计算特征相关性如表 1 所示。

表 1 高维特征相关性

	第 90 维 特征	第 96 维 特征	第 212 维 特征	第 231 维 特征	第 47 维 特征
皮尔逊系数	0.900 2	0.917 7	0.932 3	0.938 5	0.965 7
P-value	0	0	0	0	0
互相关系数	0.745 2	0.927 7	0.999 9	0.999 9	0.879 7

皮尔逊系数和互相关系数越接近 1 表示相关性越强,而 p-value 与之相反,常规机器学习特征选择皮尔逊系数阈值为 0.5。从表 1 可以看出,卷积后提取的高维特征在不同维度与刀具磨损量表现出强相关性,证明卷积操作对于提取特征的有效性。对高维特征进行 T-SNE 法降维后^[15],每个样本的特征在三维空间分布如图 5 所示。




图5 高维特征分布图

可见,每个样本对应的高维特征降维后自动成簇分布在三维空间内,不同簇与刀具磨损量阶段在空间上相互对应,进一步证明了多层卷积后的高维特征与刀具磨损状态具有强相关性高可靠性。

此外,为进一步提高性能,规范层对每个信号数据重新规范化,使其输出数据的均值接近 0、标准差接近 1,以便加速收敛、降低网络对初始权重的敏感性。激活函数选择“Relu”激活函数,使一部分神经元在传播的过程中输出为 0。这种稀疏性会减少参数的相互依存关系,提高网络的泛化能力。

Dropout 层从所有神经元连接中随机隐藏一部分神经元,以达到防止过拟合的目的。

2.3 模型的训练

模型的训练流程如图 6 所示。将数据样本按照 8:2 的比例划分为训练集和验证集,验证集全程不参与训练,只作为模型是否进入过拟合的评判依据。

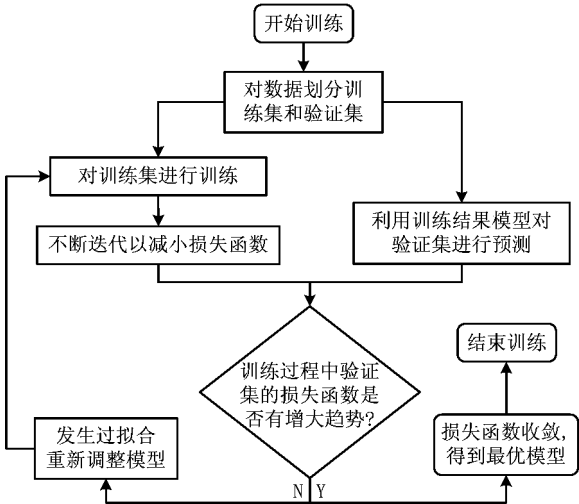


图6 模型训练过程

将训练集样本中的数据输入 DenseNet 网络中以训练权重,则每层的输出为

$$x^l = f(\prod_{n=1}^l W^n x^{n-1})。$$
 (3)

式中: f 表示 Relu 激活函数, W^l 表示第 l 层度权重。使用亚当(Adam)优化算法,以均方误差(Mean Squared Error, MSE)作为损失函数,表示监测值与真实值之间的均方误差,计算公式如下:

$$J_{MSE} = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2。$$
 (4)

式中: y_i 表示第 i 个样本的实际磨损量, \hat{y}_i 表示第 i 个样本的监测到的磨损量, n 表示监测样本总数。

利用链式求导法则计算损失函数对每个权重 W 的梯度,更新方式如式(5)所示。

$$W_{new}^l = W_{old}^l - \eta \frac{\partial J_{MSE}}{\partial W_{old}^l}。$$
 (5)

式中: η 表示学习率, W^l 表示第 l 层度权重。批次选取样本对权重进行更新,使预测值与真实值不断逼近。最终,在训练结束后,保存训练集及验证集损失函数最小的模型作为最终监测模型。

为进一步表现模型的优势,选用平均绝对百分比误差(Mean Absolute Percent Error, MAPE)和决定系数 R^2 (Coefficient of Determination)作为评

价标准。MAPE 是相对误差绝对值的均值,其计算公式如下:

$$MAPE = \sum_{i=1}^n \left| \frac{y_i - \bar{y}_i}{y_i} \right| \times \frac{100}{n} \quad (6)$$

式中 \bar{y} 为所有实际值的均值。

决定系数 R^2 表现了磨损量预测值和实际值之间的拟合程度, R^2 越接近 1, 表明模型的拟合程度越好。其计算公式如下:

$$R^2 = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (7)$$

3 实验验证

3.1 实验条件

为了便于与同类研究进行对比,本文采用美国 PHM 协会在 2010 年的刀具磨损的比赛数据^[17]。实验机床为 Rödgers-TechRFM760 高速数控铣床,实验刀具为三刃碳化钨球头铣刀,切削材料为不锈钢(HRC-52),切削参数如表 2 所示。

表 2 PHM data challenge 实验切削参数

主轴转速 /rpm	进给速度 /(mm/min)	径向切深 /mm	轴向切深 /mm	铣削方式
10 400	1 555	0.125	0.2	顺铣

实验中,通过测力仪、加速度传感器、声发射传感器采集加工过程中的力信号、振动信号和声发射信号原始时域信号。力与加速度传感器应放置于工

件或夹具上,声发射传感器应紧贴工件侧面。信号采样频率为 50 KHz,每次走刀沿 X 方向切削 108 mm,记为一个切削行程,每把刀具切削 315 个行程,每个切削行程结束后,记录刀具每个切削刃的后刀面磨损量,共采集 945 次,形成 945 个样本。其中,随机选取 756 个训练样本、189 个验证样本。每个样本包含 7 维信号和 3 个切削刃的后刀面磨损量,为防止不同刀刃磨损量之间的相互干扰,只保留 3 个刀刃磨损量中的最大值。实验软件平台利用 Keras 深度学习库进行运算,使用 TensorFlow 后端进行数据分析。实验硬件平台为 Intel Xeon 处理器,主频 2.1 GHz,32 GB 内存,NVIDIA Quadro M2000 图形处理器。

3.2 实验结果

将上述训练样本批次输入监测模型,自适应地提取切削信号中的敏感特征,计算监测值与真实值之间的 MSE,利用 Adam 算法使 MSE 下降并更改网络权重,使模型监测值更加接近真实值。训练过程中训练集和验证集的损失函数变化曲线如图 7 所示。其中,不同层数模型的损失函数下降曲线用不同线型表示, x 轴表示训练次数, y 轴表示训练集和验证集的损失函数。可以清楚地看到,随着训练次数的增多,磨损量监测值与真实值之间的均方误差不断减小,并最终收敛,说明本模型可以自适应地挖掘隐藏在信号中的切削信号特征,更加准确地识别刀具磨损量。




图7 训练损失函数曲线

通过尝试不同深度的网络可以看出,深层网络与浅层网络相比,能更好地提取信号中的特征,使得监测值与真实值之间的均方误差不断下降。但随着网络加深到一定程度,则会出现梯度弥散现象,使损失函数保持在一个较高的值无法继续下降。经过大量尝试,选择含有 9 个密集连接块,每个连接块含有 5 次卷积运算,共计 78 层的模型作为监测模型。由图 7 可以看出,随着训练的进行,78 层的模型收敛效果最好,最终在训练集上损失函数达到 2.041,而

在验证集上也达到了 9.367。可以清楚地看出,没有发生过拟合现象,表明这一模型的精度和泛化性最好。

磨损量监测的结果如图 8 所示。左、中、右 3 个图分别表示 3 个切削刀后刀面磨损量的监测结果和实际值。可以看出,刀具磨损量只在初期磨损局部存在偏差,在正常磨损和过量磨损区间监测结果较为精准。




图8 刀具磨损量监测结果

3.3 对比与分析

相同的数据也分别被用于基于 HMM、SVR、FNN 的刀具磨损监测模型^[8-9]。采用均方误差 MSE、平均绝对误差 MAPE 和决定系数 R^2 作为模型的判别准则,5 种模型在测试集和验证集上的对比结果如表 3 所示。

表 3 不同模型下实验结果

模型	数据	MSE	MAPE/%	R^2
HMM 模型 ^[9]	测试集	85.8	7.53	0.958
SVR 模型 ^[9]	测试集	238.8	9.96	0.876
BPNN 模型 ^[8]	测试集	134	6.45	0.983
FNN 模型 ^[8]	测试集	17.4	1	0.995
DenseNet	训练集	2.04	0.917	0.995
DenseNet	验证集	9.36	1.545	0.971

可以发现,传统的机器学习方法模型结果并不稳定,不同模型结果相差较大,其原因在于提取特征的优劣和建模技巧,特征提取方式不同会对最终结果产生较大影响。而本文提出的模型利用原始时域信号自适应地提取信号特征,不但证实了卷积操作在时域信号上的有效性,而且模型最终对刀具磨损定量分析的绝对偏差、相对偏差及拟合程度上均优于传统模型。由于验证集不参与训练,本模型在验

证集上的表现证实了其优异的泛化性能。

4 结束语

本文提出一种基于卷积神经网络的刀具磨损量在线监测方法。通过实验验证,这种深度学习的方法不仅可以采用原始时域信号作为输入,避免信息在降噪、小波变化等操作中造成损失,还取消了传统的人工特征提取过程,利用多层卷积、池化操作很好地挖掘加工信号中隐含的高维特征,提高了监测的精度和泛化性能,并且对当前磨损量做回归分析,以提高监测精度。通过与相关研究的对比,证实了本文提出方法在精度、拟合优度及泛化性能等方面的优势。

但是,该模型依然受到训练数据量大小和加工具体情况的制约,难以满足复杂多变的加工情况。在以后的研究中,将进一步针对监测模型的精确性和泛化性能进行研究。

参考文献:

- [1] ZHOU Y, XUE W. Review of tool condition monitoring methods in milling processes[J]. International Journal of Advanced Manufacturing Technology, 2018, 96 (5/6/7/8): 2509-2523.
- [2] DUTTA S, PAL S K, MUKHOPADHYAY S, et al. Application of digital image processing in tool condition monitoring:

- A review[J]. *Cirp Journal of Manufacturing Science & Technology*, 2013, 6(3): 212-232.
- [3] PATRA K, JHA A K, SZALAY T, et al. Artificial neural network based tool condition monitoring in micro mechanical peck drilling using thrust force signals[J]. *Precision Engineering*, 2017, 48(1): 279-291.
- [4] BHUIYAN M S H, CHOUDHURY I A, NUKMAN Y. Tool condition monitoring using acoustic emission and vibration signature in turning[J]. *Lecture Notes in Engineering & Computer Science*, 2012, 2199(1): 531-538.
- [5] MARTINS C H R, AGUIAR P R, FRECH A, et al. Tool condition monitoring of single-point dresser using acoustic emission and neural networks models[J]. *IEEE Transactions on Instrumentation & Measurement*, 2014, 63(3): 667-679.
- [6] WU Jun, SU Yongheng, ZHU Yongmeng, et al. Real-time remaining useful life prediction of cutting tool based on information fusion[J]. *Journal of Huazhong University of Science and Technology: Nature Science Edition*, 2017, 45(4): 1-5 (in Chinese). [吴 军, 苏永衡, 朱永猛, 等. 基于信息融合的刀具剩余寿命在线预测方法[J]. *华中科技大学学报: 自然科学版*, 2017, 45(4): 1-5.]
- [7] ZHANG Dongliang, MO Rong, SUN Huibin, et al. Tool wear state recognition based on chaotic time series analysis and support vector machine[J]. *Computer Integrated Manufacturing Systems*, 2015(4): 651-657 (in Chinese). [张栋梁, 莫 蓉, 孙惠斌, 等. 基于混沌时序分析方法与支持向量机的刀具磨损状态识别[J]. *计算机集成制造系统*, 2015, 21(8): 2138-2146.]
- [8] LI X, LIM B S, ZHOU J H, et al. Fuzzy neural network modelling for tool wear estimation in dry milling operation [C]//*Proceedings of Annual Conference of the Prognostics and Health Management Society*. San Diego, Cal., USA: Prognostics and Health Management, 2009.
- [9] WANG Xiaoqiang. Tool wear monitoring and remaining useful life prognosis[D]. Wuhan: Huazhong University of Science and Technology, 2016 (in Chinese). [王晓强. 刀具磨损监测和剩余寿命预测方法[D]. 武汉: 华中科技大学, 2016.]
- [10] TOBON-MEJIA D A, MEDJAHHER K, ZERHOUNI N. CNC machine tool's wear diagnostic and prognostic by using dynamic Bayesian networks[J]. *Mechanical Systems & Signal Processing*, 2012, 28: 167-182.
- [11] LIN Yang. Research on tool wear state monitoring technology of high speed milling based on deep learning[D]. Hefei: University of Science and Technology of China, 2017 (in Chinese). [林 杨. 基于深度学习的刀具磨损状态监测技术的研究[D]. 合肥: 中国科学技术大学, 2017.]
- [12] ZHANG Cunji, YAO Xifan, ZHANG Jianming, et al. Tool wear monitoring based on deep learning[J]. *Computer Integrated Manufacturing Systems*, 2017, 23(10): 2146-2155 (in Chinese). [张存吉, 姚锡凡, 张剑铭, 等. 基于深度学习的刀具磨损监测方法[J]. *计算机集成制造系统*, 2017, 23(10): 2146-2155.]
- [13] HINTON G E, OSINDERO S, TEH Y W. A fast learning algorithm for deep belief nets[J]. *Neural Computation*, 2006, 18(7): 1527-1554.
- [14] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. *Computer Science*, 2014.
- [15] HUANG G, LIU Z, MAATEN L V D, et al. Densely connected convolutional networks [C]//*Proceedings of IEEE Conference on Computer Vision and Pattern Recognition*. Washington, D. C., USA: IEEE Computer Society, 2017: 2261-2269.
- [16] LAURENS V D M, HINTON G E. Visualizing data using t-SNE[J]. *Journal of Machine Learning Research*, 2008, 9 (2605): 2579-2605.
- [17] PHM Society. PHM data challenge 2010[DB/OL]. <https://www.phmsociety.org/competition/phm/10>.

作者简介:

曹大理(1993—), 男, 陕西延安人, 硕士研究生, 研究方向: 复杂产品数字化产品设计, 智能制造, E-mail: yanancaodali@163.com;

孙惠斌(1977—), 男, 陕西榆林人, 副教授, 博士, 博士生导师, 研究方向: 智能制造、智能感知与预测、精密装配工艺基础等, E-mail: sun_huibin@nwpu.edu.cn;

张纪铎(1995—), 男, 湖北汉川人, 博士研究生, 研究方向: 复杂产品数字化产品设计, 智能制造;

莫 蓉(1957—), 女, 湖南常德人, 教授, 博士, 博士生导师, 研究方向: 数字化设计与制造、智能化设计与智能制造、集成制造与服务型制造。