

航天器遥测数据异常检测综述^{*}

彭喜元, 庞景月, 彭宇, 刘大同

(哈尔滨工业大学电气工程及自动化学院 哈尔滨 150080)

摘要:航天器遥测数据是地面运管系统判断其在轨运行状态的唯一依据,其异常检测成为增强航天器在轨可靠性和安全可靠运行的重要依据。但是,遥测数据量大、维度高、参数关系复杂、专业性强的特点为高检测率、低误检率、强解释性的遥测数据异常检测实现带来严峻挑战。本文对航天器遥测数据异常检测领域进行充分的调研,阐述遥测数据异常检测内涵、方法研究及应用现状,尤其针对数据驱动的遥测数据异常检测方法体系进行了系统、详细的分析,并在此基础上归纳总体发展动态,展望未来发展方向,以此为相关研究者提供参考。

关键词: 航天器;遥测数据;异常检测;数据驱动

中图分类号: TP311 **文献标识码:** A **国家标准学科分类代码:** 510.4030

Review on anomaly detection of spacecraft telemetry data

Peng Xiyuan, Pang Jingyue, Peng Yu, Liu Datong

(Department of Automatic Test and Control, Harbin Institute of Technology, Harbin 150080, China)

Abstract: Spacecraft telemetry data is the only basis for ground operation and management system to determine its on-orbit state, and the anomaly detection of which has become the important mean to enhance the spacecraft's on-orbit reliability and safety. However, telemetry data has the characteristics of large amount of data, high dimension, complex relation which bring severe challenges for the realization of anomaly detection with high detection rate, low false detection rate, and strong interpretation. In this work, the full analysis has been conducted on the anomaly detection area of spacecraft telemetry data. The anomaly detection definition, anomaly detection connotation, anomaly detection method research and application status have been explained in detail. Especially, the data-driven methods are emphasized system atically and effectively. Furthermore, the paper summarizes the overall development and look to the future direction to provide reference for the related researchers.

Keywords: Spacecraft; Telemetry data; Anomaly detection; Data-driven

1 引言

航天器自设计、研制、生产至在轨运行,会消耗大量的人力、物力及财力,其系统结构复杂,承担着重要的气象观测、军事侦察和资源考察等任务,对国家的发展和民族的进步具有战略性影响^[1]。但是,随着航天器研制复杂性的提高,其在轨故障率明显增加^[2],如2006年统计的我国在轨的25颗卫星共发生过约97次故障,因此,增强航天器在轨可靠性成为航天领域重要的关注内容。而

伴随着传感技术、信息技术等发展,结合高技术装备项目(如:美国的JSF),诞生了以预测为核心,从状态监控到健康管理的故障预测与健康管理(prognostics and health management, PHM)策略,其迅速在航天飞行器、飞机等军事装备中得到足够关注,使得综合诊断逐渐向测试、监控、预测及诊断综合一体化发展。尤其是近两年大数据和云计算技术的推动,工业4.0、信息物理系统(cyber-physical system, CPS)及中国制造2025等概念的提出使得监测数据成为增强航天器在轨可靠性的高价值资源,受到研究学者的广泛关注。

收稿日期:2016-08 Received Date: 2016-08

^{*} 基金项目:国家自然科学基金(61571160, 61301205)、部委重点基金课题(9140A17050114HT01054)、哈尔滨工业大学学科发展新方向(01509421)、中央高校基本科研业务费专项资金(HIT. NSRIF. 2014017)项目资助

航天器在轨运行期间,其内部的运行状态监测系统获得的传感器参量信息编码后,通过遥测系统传输至地面,此遥测数据是地面航天飞行器运管人员了解航天器在轨运行状态的唯一依据。遥测数据量大、维度高、关系复杂、相关性 & 专业强属于工业大数据的典型应用领域,其反映航天器所处的轨道信息、性能变化、工作模式切换以及是否出现故障等,对遥测数据的有效分析和智能计算将为地面运管人员判断航天器的性能,开展各种运行和维护管理工作提供有效依据。尤其是遥测数据中的异常数据,其不同于正常遥测数据的变化规律或不符合航天器工作模式设定,从而可以反映采集设备失效、传输链路受损、对应设备的性能退化、质量问题、机械及电子故障,或者设计不足等问题。及时而有效地发现遥测数据中存在的异常模式,并对被测设备进行远程指令修复、传输链路修复、软件故障排除、故障预案制定,或者维护服务优化等操作,对于提升地面服务质量,增强航天器设计、研制、生产以及维护各个环节的成熟度、安全性及可靠性具有显著的现实意义。

鉴于此,工程上一直采用传统的人工数据判读、阈值自动判读以及专家经验的手段进行遥测数据异常检测。这些方法简单且容易实施,可有效地检测部分预设异常,但是其对于很多初期并不超过设定阈值的异常模式往往无能为力,且不能检测尚未被认知的异常事件。

随着航天器功能复杂化以及类型多样化,在轨航天器数目逐年增多,需实时监测的遥测数据维度呈膨胀式发展(单颗卫星的遥测数据已突破三四千维,全寿命遥测数据量更是高达 TB 级),单纯依靠人力以及专家经验实现遥测数据实时监测已经不能满足现实的技术发展需求。因此,为了实现航天器系统工程的工业化运营管理,急需通过对航天器遥测大数据分析,实现数据采集、传输、存储到数据价值挖掘以及决策支持的过渡。因此,以传感器监测数据为基础,数据驱动的自动异常检测技术成为国内外研究的热点所在,其受到关注的主要原因包括:1)数据驱动方法无需提前获知专家经验,能够通过正常数据分析检测未知的以及处于阈值内的异常模式;

2)扩展性强,可同时用于多种遥测以及不同类型航天器的异常发现;3)自动检测方式,在提升效率的同时可显著降低系统工作负担。基于数据驱动的航天器遥测数据自动异常检测技术已经成为具有现实工程价值的研究主题。

而近年来,中国航天器不仅发射数目多,而且发射频率越来越大^[3]。因此,强大的航天器功能需求使得今后无论是单个航天器遥测数据量,还是同时在轨管理的航天器数目将呈现逐级增长,加之遥测数据具有特征冗余、关系复杂、数据间关联性及专业性强等工业大数据的典型特点,我国航天技术领域更急需对航天器遥测数据异常检测研究进行充分的调研和分析,归纳并总结遥测数据异常检测发展体系及技术发展,加速推进航天器遥测数据异常检测的研究和应用进程。

目前,虽然航天器遥测数据异常检测已经得到相关领域研究学者的关注,但是研究的内容相对分散,不成体系,且很多研究工作还仅仅是围绕其研究机构的个性化需求出发,忽略了整个行业的国内外研究基础,很难较快地应用于航天器地面长管系统的运营维护。因此,本文尝试从遥测数据异常的特点出发,归纳总结航天器遥测数据异常检测方法的研究现状,对其中涉及的关键技术进行阐述,力求为航天飞行器遥测大数据的工业化管理和分析的技术发展,提供可行的研究思路。

2 航天器遥测数据异常检测基本概念及内涵

2.1 航天器遥测数据基本概念

航天器在轨运行期间,为了获取其内部运行状态,并为遥控对象提供实时数据,航天器遥测系统中的传感器感受被测量并转换为电信号,各路信号按一定体制组合后,利用无线电通信技术传输至地面遥测设备(包括接收机、天线以及分路解调器等组成),地面设备通过信号解调技术恢复各路原始参量信息,并进行存储、显示,在这种情况下获得的参量信息即为航天器遥测数据^[4],按照不同的分类标准,将遥测数据划分为如表 1 所示。

表 1 遥测参数类型划分
Table 1 Telemetry data type

分类标准	类别	举例
按照数据特点	数字量	单元的开/关机情况
	模拟量	温度、电压、电流、压力
按照数据存储类型	整型	标识字、状态字
	浮点型	温度、电压、电流、压力
按照物理量	相同物理含义的参量	电压、电流、温度、角度等
按照分系统	相同子系统的参量为一类	推进、电源、姿轨控、星务等
按照数据变化幅度	静态参数	门限内模拟量遥测输出平稳
	动态参数	在门限内有较大波动
	慢遥测	采样率较小
按照卫星采样率	快遥测	采样率较大
万方数据		

航天器遥测数据量大、关系复杂、专业性强,属于工业大数据的典型应用领域,以某卫星为例,其遥测参量采样率低至0.5 s,每次下传数据量为256 B,以其在轨寿命为8年计算,则其全寿命周期解析的物理量及原码之和达TB级。丰富的航天器遥测数据其与被测设备的性能状态息息相关,反映了设备的功能以及性能变化,是地面运管人员了解航天器在轨运行状态的唯一依据。

当航天器出现异常状态时,如辐射和温度变化引起的器件损坏;机械部件由于长期使用导致机械阻力增大;电子线路老化,短路、断路情况发生;蓄电池随着充放电次数增多而导致性能退化等。其将表现在直接监测量——航天器遥测数据上,遥测数据异常类型可分为单元以及多元异常,其细分情况如图1所示^[5]。

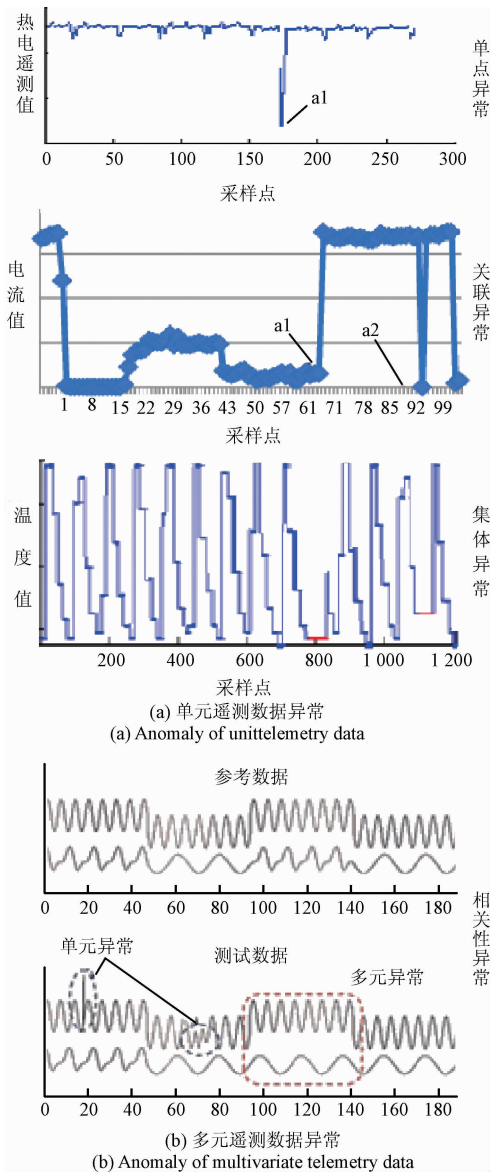


图1 航天器遥测数据异常类型

Fig. 1 Type of spacecraft telemetry data

如图1所示,航天器单元异常又细分为单点异常、关联异常、集体异常,这与时间序列单元异常^[6-7]的分类情况类似,主要是由于遥测数据也是以时间先后顺序采集,并存储,属于时间序列的一个应用领域。

1) 单点异常

将航天器数据作为整体,其个别的数据点不同于剩余正常的数据点,并且在航天器遥测数据中认为是异常的,那么这个点被称作单点异常。如图1中单点异常子图的a1点所示。

2) 关联异常

如果一个点在特定环境处出现异常,则称为关联异常。由于多数情况下遥测数据的上下关联环境为时间,所以此处的关联异常通常指的是时间上下文的关联异常,如图1中关联异常子图内a1点的电流值与a2点的电流值类似。但是由于时间上下文关联环境不同,即电流的工作模式不同,a1点为正常数据,而a2点则为异常数据。关联异常也称为上下文异常。

3) 集体异常

如果个别的数据点存在于一个集合中,它们本身不是异常,但是它们一起出现的点集合被认为是异常,那么这些关联的数据点的集合被称作集体异常,也称为子序列异常或聚集异常。如集体异常子图中红色区域出现一系列数值,其改变了遥测温度的变化趋势,属于异常子序列。

4) 多元异常

在文献[8]中研究学者提到航天器类多元异常主要表现为两种形式:(1)多元变量中的某一变量的遥测出现了问题,其被划分为单元异常;(2)单遥测数据本身并未发生异常,而是多元遥测数据之间的相关性发生了变化,则称其为多元异常。如图1中相关性异常子图,其左侧虚线为单元异常,而右侧区域标注的则是多元异常,由右侧区域可知,两个维度都是正常的工作模式,只是模式对应情况发生了变化,此种情况下的异常为多元异常。

2.2 异常检测内涵

目前针对异常还没有一个公认的定义,人们普遍采用的是Hawkins D. M.^[9]给出的解释是异常是在数据集中偏离大部分数据的数据,使人怀疑这些数据是由不同的机制产生,而非随机偏差;Johnson R^[10]在1992年提出:“异常事件是数据集中与其它实例相比并不一致的观测实例”;相似地,1994年Barneet V等人^[11]将异常定义如下:“异常或者异常事件是与同类事件相比偏差较大的实例”;而Keogh E等人^[12]最早提出时间序列异常的概念,其指出时间序列的异常应该具有两个重要的性质:异常位置与滑动窗口的大小无关;低维的异常扩展至高维不一定成立。虽然目前关于异常并没有统一的定义,但是不同的研究学者在自己的研究过程中都提出了不同的异常的定义,如新颖(novelty)^[13]、不一致(discord)^[14]、奇

异 (surprise)^[15]、变化点 (change point)^[16]、异常 (anomaly)^[17]、“不正常的”(deviant)^[18]等。

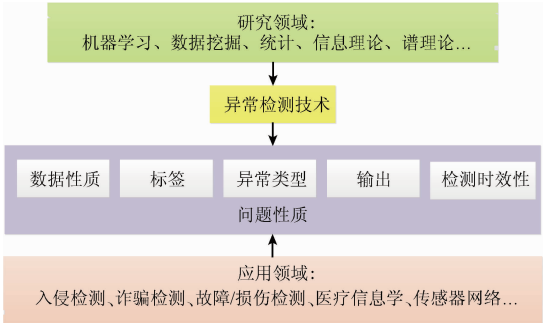


图 2 与异常检测方法相关的因素
Fig.2 Key components associated with anomaly detection methods

异常检测主要是采用一定的方法将异常行为从正常行为中分离出来,异常检测方法具有重大的意义以及参考价值,与异常检测方法相关的因素^[7]如图 2 所示。

异常检测方法在多个领域具有强烈的需求,如网络入侵检测、金融风险分析、工业控制管理、医疗病例分析、

传感器网络等,利用异常检测技术分别实现入侵行为识别、大量股票数据的异常分析、优化生产过程及质量控制、病人的病情反馈、相应测试环境或者测试系统的变化及故障检测。

而不同的应用领域所面临的具体问题不同,如数据性质,涉及连续属性数据、分类属性数据;标签主要包括已获得的数据所具有的正常及异常标签;异常类型则指的具体的异常模式特征,如单点异常、连续异常等;输出则指异常检测输出的标记,涉及标签及异常分数;检测时效性,则是对应使用异常检测的在线及离线方式;在文献[7]中详细综述了各个因素的具体内涵。具体需求的不同因素限定了异常检测方法的选择范围及使用方式,而异常检测方法的理论多来自于机器学习、数据挖掘、统计学、信息理论等领域。

2.3 航天器遥测数据异常检测内涵

航天器遥测数据异常检测则是利用一定方法实现遥测数据中的不一致成分发现,其属于异常检测的一个应用领域,该领域待检测的遥测数据的问题性质分析如表 2 所示。

表 2 航天领域异常检测问题性质分析

Table 2 Analysis on problem characteristics in Space area

因素名称	特点	说明
数据性质	连续型 离散型	离散型数据状态固定,异常状态较容易发现,连续型数据的异常检测是该领域的检测重点
标签	大多数为正常数据标签,含有少量异常标签	异常标签来自于已发生的故障数据,而隐含在正常数据中的异常数据标签并未给出
异常类型	涉及单点异常、关联异常、集体异常、多元异常	遥测数据具有时间特性,其与时间序列异常类型相似
输出	标签或 异常分数	标签或者异常分数的形式在该领域均可接受
检测时效性	在线及离线	在线检测可支持实时决策,离线检测可定期执行,发现长期潜在异常

针对于表 2 中关于问题性质的分析以及航天领域特点,对遥测数据进行异常检测的方法主要涉及 4 大类:基于人工监测结合阈值的检测方法、基于专家系统方法、基于专家经验的模型构建方法和基于数据驱动的异常检测方法。以上遥测数据异常检测的方法将在第 3 节进行详细描述。

3 航天器遥测数据异常检测技术体系

针对于航天器遥测数据异常检测的 4 大类方法:基于人工监测结合阈值的检测方法、基于专家系统方法、基于专家经验的模型构建方法和基于数据驱动的异常检测方法和其检测流程如图 3 所示。

在以上检测方法中,基于人工监测结合阈值的检测方法、基于专家系统以及基于专家经验模型的方法都不

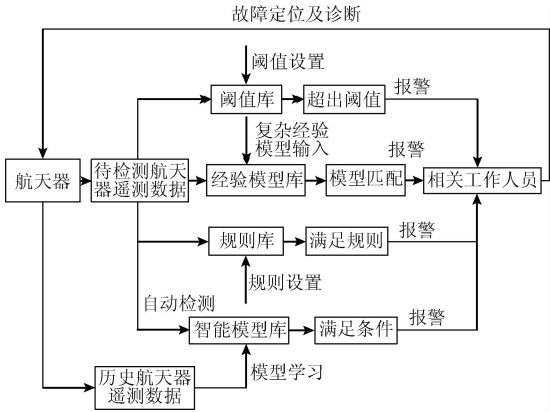


图 3 不同航天器遥测数据异常检测方法流程
Fig.3 The flow chart of different anomaly detection methods for spacecraft telemetry data

具备学习能力,其依赖于专家知识,而基于数据驱动的方法则可通过历史遥测数据建立智能模型库实现自动的异常识别。各检测方法关系如图4所示。

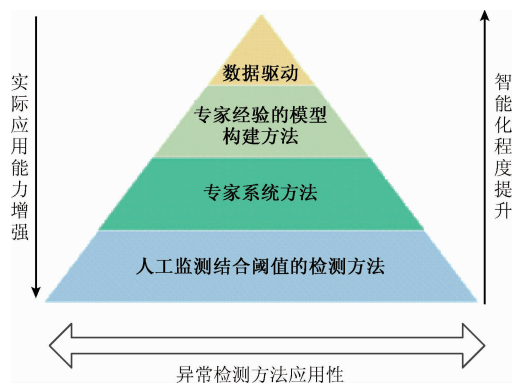


图4 航天器遥测数据异常检测方法

Fig.4 Anomaly detection methods of telemetry data

基于数据驱动的方法其智能化程度最高,是目前航天器遥测数据异常检测领域的研究热点,但由于其不依赖于专家知识,在实际的航天器地面监测系统中应用还相对较少,而基于专家经验的其他3种方法由于与航天器本身的设计知识相关,可以很好地检测出预设的异常模式。

3.1 基于人工监测结合阈值的检测方法

本种方式是最传统的,也是实际航天器地面长管系统普遍采用的较可靠的异常检测方法。航天器在轨工作过程中,工程技术人员对遥测数据进行近乎实时的观测,并辅以信号阈值以监测信号是否超出预设的范围,例如总线电流、电压、角速度、温度值是否超出预设的上下限值,一旦超出此范围,则发出警告。通常,门限值的监测只针对部分遥测序列,而不是所有序列^[19]。

优点:该方法操作简单,利于工程技术人员在地面监测系统执行,而且该方法可以检测出大量生产制造中的异常。

技术问题:1)存在大量异常,其症状并不能通过简单的监测上下限值来进行检测,换言之,很多类型的异常发生时并不会引起变量超限。2)预设大量变量的限值,人力成本高,并且考虑不同的工作状态来调整限值是非常费时费力的。而且一旦阈值设置不合理,其不仅不能有效检测异常,还会引起大量虚假警报,导致工作人员忽视真正的异常事件。3)阈值设定的可扩展性差,监测航天器更换时,阈值就需要重新设定,不具备普遍适应性。

3.2 基于专家系统方法

专家系统也是应用比较广泛可靠的异常发现手段,专家知识通过以“if-then”的规则形式表达。如ISACS-DOC(intelligent satellite control software DOctor)^[20],其专家系统是由日本空间科学研究所ISAS和日本宇宙航空研究开发机构联合开发,其已经应用于一系列执行深空探测任务的卫星中,如GEOTAIL、NOZOMI以及

HAYABUSA,使用时间已经超过十年。而且我国的航天器长管系统中也开发了以专家知识为基础的自动规则检测工具,实践证明其对于部分异常具有良好的检测及识别效果。

优点:专家系统在表示以及诊断能力上远超过阈值方法。

缺点:虽然专家系统是相对强大且灵活的,但是由于航天器系统复杂,很难建立准确且完备的航天器规则。而且因为在设定规则库时需要列举所有故障及其征兆,基于专家系统的方法很显然不能处理未知的异常。一旦设计改变,很难保证规则的一致性。

3.3 基于专家经验的模型构建方法

基于专家经验的模型构建方法指的是将专家经验编码为模型,然后用于自动检测故障,采用这种方法的系统包括Livingstone^[21]、HyDE^[22]、Titan^[23]、TEAMS-RT^[24]、RODON^[25]、SHINE^[26]以及MEXEC^[27]。其中比较典型的是Livingstone以及TEAM-RT系统,Livingstone是由美国宇航局(NASA)开发的快速、基于模型的自主配置系统,其采用基于元件的离散模型对航天器系统进行描述,通过模型预测结果和传感器测量结果的比较,判断航天器的故障,并选择故障的最佳恢复方案^[28],Livingstone是NASA's new millennium program中的第一个飞行器—DS-1(Deep Space One)核心自主结构的重要组成部分;TEAMS是由OSI公司开发的基于模型的分析工具,支持复杂系统全寿命周期的测试时序生成以及测试性设计、分析,其模型涵盖了系统的结构、互联、测试布局、测试步骤、故障等信息,并可将各种故障与系统的BIT、维护步骤和修理过程关联起来^[29]。

但是无疑建立这些模型是非常费时的,因此不可能针对大型复杂系统建立其各部分的模型。更不可能对每种可能的异常模式进行建模。

3.4 基于数据驱动的异常检测方法

基于数据驱动的异常检测方法采用统计、机器学习以及人工智能等理论对遥测数据进行建模、刻画,以识别不符合正常数据的异常模式。考虑到基于数据驱动的遥测数据异常检测方法不依赖于专家经验,而仅根据遥测数据进行异常发现,因此航天器遥测数据将转化为时间序列,其异常类型与时间序列异常类似,而基于数据驱动的航天器遥测数据异常检测也成为时间序列异常检测的一个应用领域,本部分将结合时间序列异常检测研究,先综述数据驱动的异常检测方法,并以遥测数据异常类型为问题出发点,有针对性地分析对应3种异常类别的检测方法,并对其技术特点、适应性等进行分析。

3.4.1 数据驱动的异常检测方法

对于不同的异常类型,其主要的区别在于异常数据的输入、输出以及在进行异常检测前的处理,而其最终使用的检测方法所使用的度量因子基本类似,因此本文通过对数据驱动的异常检测方法的大量调研及分析,将数

据驱动的异常检测方法分为基于相似性、基于偏差以及基于概率的方法。

1) 基于相似性的方法

其是按照正常数据与异常数据的相似程度进行划分,与其它数据相似性较低的数据即为异常数据,因此其应用前提在于数据集中正常数据占大多数,只有少部分

为异常数据。该方法具体包括:基于距离、基于密度、基于强力搜索、基于聚类方法。

其方法的优点在于只要找到合适的度量函数,基于相似性的方法可以准确地检测出异常的数据;缺点在于其对度量函数高度依赖,且易受噪声影响。

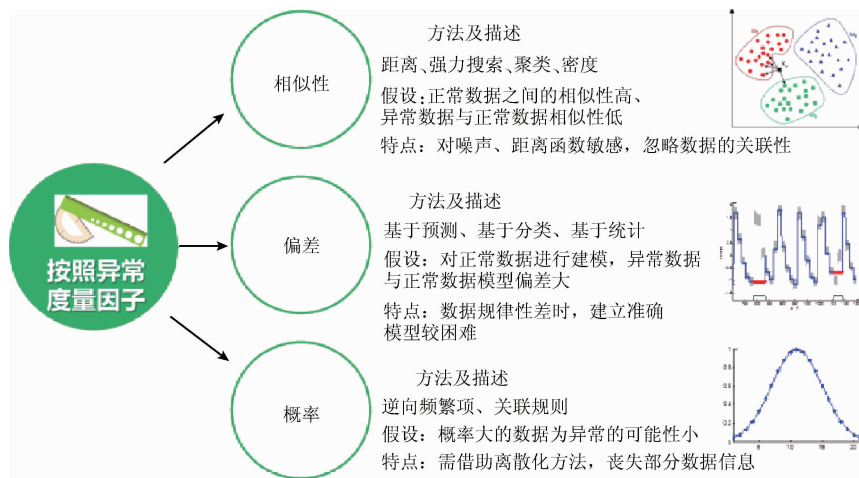


图5 数据驱动的异常检测方法

Fig. 5 Data-driven anomaly detection methods

2) 基于偏差的方法

基于偏差的方法其通过已知的正常数据建立模型,比较测试数据,与正常数据模型偏差较大的,即为异常数据。该方法具体包括基于预测、基于分类以及基于统计方法。

基于偏差的方法优势在于模型建立后,测试数据检测效率高;缺点在于建立准确的模型较困难。

3) 基于概率的方法

基于概率的方法主要是比较不同数据在数据集中发生的概率,其假设在于正常数据发生的概率高,而异常数据出现的概率低,该方法包括逆向频繁项方法以及关联规则方法。

该类方法优势在于有很好的概率以及理论基础;缺点在于为了统计数据发生的概率,通常需要将数据进行离散化表示,会丧失部分细节信息。

3.4.2 数据驱动的遥测数据异常检测方法

数据驱动的异常检测方法为遥测数据异常检测提供了方法基础,而由于领域的问题性质不同,其使用的方法会具有差异性,本文在表2中重点分析了航天器遥测数据异常检测的内涵,对遥测数据异常检测方法起到关键影响的是遥测数据的异常类型,因为没有有一个检测方法是万能的,可以有效地检测所有的异常类型,即异常检测方法对不同的异常类型的适应性及有效性不同,所以本部分以遥测数据异常类型问题出发点,以检测方法为主线,阐述其研究现状。

1) 遥测数据关联异常检测

对于遥测数据关联异常检测,其输入为多个按照时间顺序排列的序列点,其输出为异常的数据点,因此应重点考虑数据之间的时间上下文特性,由于航天器的规律性运行以及工作模式的设定影响,大多数遥测数据呈现出周期、趋势等特性,因此针对此种异常主要采用的方式是基于偏差方法中的基于预测模型的方法。

基于预测模型的异常检测^[30]是在预测方法得到研究学者广泛关注的基础上提出的,该方法假设数据随着时间收集的过程中,数据之间具有一定的关联性,当前数据可以通过历史窗口数据建立的模型外推得到。正常数据的范围是通过历史窗口模型的预测均值和预测方差确定的置信区间,当观测数据超出该范围时,则认为数据出现了异常事件。其检测原理如图6所示。

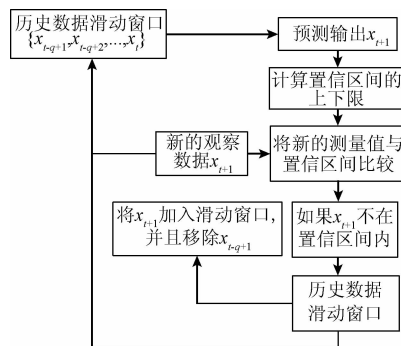


图6 基于预测模型的异常检测流程

Fig. 6 Anomaly detection based on predicted models

目前很多预测模型都被应用于遥测数据的异常检测中,具体如表3所示。

遥测数据关联异常是常见的基本异常类型,其以数据点作为输入输出,由于航天器在轨运行受到空间环境以及传输链路影响,正常数据也在一定范围内波动,基于预测模型的方法将通过建模对正常数据的波动范围进行

描述,因此在采用预测模型进行遥测数据异常检测时,应重点考虑模型选择以及参数优化、训练数据选择等问题,其都将影响建模的准确性,进而影响正常数据波动范围的计算,这无疑也是基于预测模型的异常检测方法待优化以及研究的重点内容。

表3 基于预测的遥测数据关联异常检测
Table 3 Context anomaly detection based on prediction

检测异常类型	检测方法	具体算法及文献
关联异常	基于预测的方法	ARMA 预测模型 ^[31]
		最小二乘支持向量机(least squares support vector machine, LSSVM) ^[5]
		相关向量机(relevance vector machine, RVM) ^[19]
		核主成分分析(kernel principal component analysis, KPCA) ^[19]
		动态贝叶斯网络(dynamic bayesian networks) ^[19]

2) 遥测数据聚集异常检测

遥测数据聚集异常是以数据向量作为输入输出,因此涉及对遥测数据的子序列分割技术,目前对遥测数据分割的方法主要包括基于物理特性以及数据特征两种方法,其中基于物理特性包括基于周期、轨道幅角等,基于

数据特征方法主要采用特征点进行序列分割。而建立在子序列分割基础上的聚集异常检测主要包括基于相似性以及基于偏差的方法,其中基于相似性方法包括基于距离、密度、聚类方法。而基于偏差的方法主要涉及基于预测的方法,其具体如表4所示。

表4 遥测数据聚集异常检测
Table 4 Subsequence anomaly detection for telemetry data

检测异常类型	检测方法	具体算法及文献
聚集异常	基于预测的方法	LSSVM
		层次聚类+KNN 分类 ^[33]
	基于相似性方法	extracting significant temporal patterns ^[34]
		基于动态时间规整(dynamic time warping, DTW)匹配 ^[35]
		基于统计特征值的 LOF ^[36]

(1) 基于预测模型的方法

其根据正常数据建立预测模型,对于测试数据判断其与正常数据的差值,如果差值超过一定范围则认为其属于异常数据。该方法通过对窗口内子序列每个数据的异常分数进行融合得到整个子序列的异常分数,文献[37]采用了 AR、SVR、FSA-z 用于时间序列异常检测,将各点的异常分数融合得到待检测子序列的异常程度。文献[32]利用 LSSVM 方法实现时间序列异常片段的检测。

(2) 基于相似性方法

基于距离的方法建立在时间序列分割的基础上,对各个子序列计算其到第 K 个邻居的距离作为每个子序列异常度的衡量,越异常的序列,其与其他子序列的距离越远。但是当原始序列含有多个类别簇时,使用基于距离的方法效果欠佳。因此在基于距离方法的基础上,提出了基于密度的方法,其计算当前序列的 K 个邻居的 K 近邻距离,然后将待测试序列的 K 近邻距离与其 K 个邻居的 K 近邻距离比值计算,密度越小,则说明该序列为

异常序列的可能性越大。在基于距离以及基于密度的基础上,很多专家学者也对其进行了改进,如文献[38]将基于距离和基于密度的方法结合起来,增加了时间序列异常检测的精度。

基于聚类的方法是将一个对象的集合分割成几个类,每个类内的对象之间是相似的,但与其它类的对象是不相似的。所以聚类方法主要是用于发现类别簇的,而之所以可以将其用于异常检测,主要是基于以下3种假设形式^[7]:假设1,在聚类过程中,不属于任何一个簇别的子序列为异常序列;假设2,簇别中含有少量数据的类别所包含的序列为异常序列;假设3,距离簇别距离较远的子序列为异常子序列。基于以上不同的假设,可以将聚类方法用于时间序列异常子序列检测。目前,已经有大量常规聚类方法用于异常检测中,如文献[39]将 BIRCH (balanced iterative reducing and clustering using hierarchies) 算法用于大规模时间序列的极值点聚类,将异常分数高的子序列作为异常序列;文献[40]利用层次

聚类算法建立异常聚类特征树来实现异常子序列挖掘。

以上方法中,基于相似性的方法在遥测数据异常检测中研究较为广泛,主要因为遥测数据具有一定的周期、趋势特性以及可按运行轨道划分的特点,基于相似性的方法可通过选择合适的度量函数衡量其序列的相似性,进而得到有效的异常检测结果;而基于预测的方法则需要对遥测数据建立模型,模型的准确度制约了异常检测的精确性。

以上方法存在的技术问题在于基于相似性的方法忽略了各个子序列的时间特性,即其面向的异常为全局异常,会导致部分局部异常子序列漏检,且相似性方法的距离函数选择是算法是否有效的关键;而基于预测的方法

模型准确性受限,且其通过片段中各个点的异常分数融合的方式确定片段的异常度,因此其易受到序列中个别点影响。

3) 遥测数据多元异常检测

多元时间序列具有数据量大、维度高、变量相关性高、大量噪声干扰等特点,使异常检测变得更加困难^[41]。尤其是航天领域,为了增强设备感知能力,往往会布置大量传感器,并对关键参数采取冗余设计,遥测数据更是呈现高维特性。且航天器由多个子系统构成,各个遥测参数的关系复杂,因此为了实现多元遥测数据异常检测,通常需对其进行降维以及特征提取操作。目前遥测数据多元异常检测主要从以下四方面开展研究^[8]。

表 5 遥测数据多元异常检测

Table 5 Anomaly detection for multi-dimension telemetry

异常类型	检测算法	具体算法及文献
多元异常	基于子空间计算	Orca ^[42] 、GritBot ^[43] 、IMS(inductive monitoring system) ^[44-45] 、K-means ^[46] 、Expectation Maximization ^[46] 、OCSVM(one-class support vector machine) ^[47] 、PLSDA ^[48]
	基于生成模型估计	dynamic grouped mixture models ^[49]
	基于基础模式重构误差	sparse representation and latent semantic analysis ^[8]
	基于构造图	box modeling algorithms ^[50]

(1) 基于子空间计算的方法

该方法将多元时间序列看作是分布在高维空间中的一系列独立样本,由于系统行为的限制,数据样本可以嵌入到低维子空间,因此可以通过监测子空间的偏离检测异常现象。可用于子空间辨识的最广泛的方法是 PCA,PCA 属于线性维度约简技术,可以采用 PCA 对原始多元时间序列进行降维处理,得到主成分序列,然后计算各主成分序列间 K 近邻以及局部异常系数,进而输出具有较高异常系数的多元时间序列^[51]。由于 PCA 不适宜于非线性系统建模,很多文献也提出了相应的扩展方法,如文献[52]将概率 PCA 混合模型用于航天器遥测数据的异常检测,取得了较好的检测结果。此种方法虽然可以捕获多元变量之间的相关性以及空间特性,但是却忽略了信号的时域相关性。

(2) 基于生成模型估计的方法

该方法通过构建数据的生成模型,将具有较低概率的数据点作为异常点检出,该方法具有坚实的数学理论基础,如果估计准确可以有效表达时间序列的空间以及时间关系,常用的模型包括向量自回归模型(vector autoregressive, VAR)以及状态空间模型(state space models, SSMs)。文献[53]使用主方向矢量内积作为异常的度量,并采用 vMF 分布表征主方向矢量分布来进行多变量时间序列异常检测,检测过程中使用历史数据训练获取分布模型的参数估计,通过计算实际数据主方向矢量在训练模型中的概率来判断异常的发生情况。其缺点在于缺乏先验知识时,很难识别数据分布以及估计模型

参数。

(3) 基于构造图的异常检测方法

此种方法根据时间序列性质构建图结构来进行异常检测。Ide 通过传感器信号之间的关系来定义图结构,其假设在正常情况下,临近的图结构会具有一定的保持特性,以此来检测异常^[54];Qiu H 等人^[55]提出研究多元时间序列的格兰杰因果关系的图模型来检测异常;文献[56]提出构建核矩阵以及其排列的图结构来进行异常检测。基于构造图的异常检测方法可以同时兼顾数据的空间关系以及时域相关性,但如果涉及的变量较多,图边缘的数量会很大,因此需要设计相关技术以减少其计算复杂度。

(4) 基于基础模式重构误差的异常检测方法

该方法通过稀疏编码的特征提取方法以及基于维度约简的关系学习技术来同时兼顾多元时间序列变量之间的关系以及时域相关性^[8]。具体地,其分为两个阶段:第 1 阶段采用稀疏编码技术实现特征提取^[57],得到各元变量的基础变化模式;第 2 阶段采用维度约简技术(latent semantic analysis, LSA)进行关系学习,确定基于训练数据基础模式的稀疏编码矩阵的重构误差,重构误差越大,则该窗口内的多元时间序列的异常程度越高。

以上方法应用于多元遥测数据异常检测时,其存在的技术问题以及适应性问题如下:基于子空间变换方法通常会忽略模式的局部变化规律,导致部分按轨道规律变化的异常模式漏检;且遥测数据之间关系复杂,采用生成模型方法时,很难建立精确的模型,导致检测精确度降

低;而基于构造图的方法对于维度较高的待检测遥测数据,其需要计算多个图边界,算法复杂度高;而基于模式重构误差方法虽然不需要构造图以及生成模型,但是该方法的关键在于如何确定基础模式个数,如果模式较准确,则重构误差可准确反映时间序列的偏离情况。

3.5 航天器遥测数据异常检测方法分析

由于航天器结构复杂,遥测数据量大、专业性及相关性,专家经验在实际的工程应用中仍然占据重要位置(这种方法对于表2中的因素特点考虑较少,主要从领域知识出发实现异常检测),尤其是在国内,航天器的故障以及异常发现是采用阈值形式进行判读,并根据阈值进行诊断,当部件或设备失效后直接切换到备机,复杂的故障情况则基本上采用地面专家会诊方式实现,仅是某些对平台不具有安全影响的故障可经设计师确认,由运管人员直接操控。因此国内的基于数据驱动的航天器异常检测仍处于实验阶段,但是随着航天器发射数目以及密度提升,可靠性要求提高,大多数在轨遥测数据的异常未知,依靠专家经验无疑很难识别,基于数据驱动的方法已经成为现在及未来遥测数据异常检测的重点。

通过3.4节对基于数据驱动的遥测数据异常检测方法的阐述,目前针对航天器遥测数据的各种异常类型都已经采用了不同的研究方法进行研究,关联异常大多采用基于预测的方式,以较好地融合数据的时间特性,而且由于预测模型可以在线应用的特点,对于流式异常检测,可采用在线的预测模型进行实时的异常点检测;而针对子序列的研究,由于其涉及到模式的检测,所以研究的相对较少,基于预测模型的方法采用预测点异常分数融合的方式得到异常子序列的分数,而基于相似性的方法则将原始时间序列进行分割后,通过距离度量得到异常子序列,方法在实施过程中主要忽略了局部异常的影响;而面向遥测数据多元异常检测,应用较多的是基于子空间计算的方法,其仅将多元时间序列看作是空间中的点,而忽略了其时间的连续性。

目前虽然基于数据驱动的遥测数据异常检测已经获

得了广泛关注,但是在各类型异常检测过程中,由于遥测数据本身的周期性、趋势性以及不确定性等特点,很多算法在应用时还需进一步的改进及提升才可以更好地应用于遥测数据异常检测,而且由于遥测数据本身的物理特性限制,算法的检测率,包括误检率以及漏检率还需要进一步提升,以增强其实际应用能力。

4 航天器遥测数据异常检测方法应用现状

4.1 国外遥测数据异常检测方法应用现状

由于航天器遥测数据与设备的运行状态息息相关,国内外已经逐渐关注到其异常分析与应用。尤其是基于数据驱动的异常检测方法被很多研究机构用来进行实际的航天器遥测数据监测工作。国外开展航天器遥测数据异常检测工作的机构包括 NASA、日本东京大学、日本宇宙科学研究所、美国空军实验室 (air force research laboratory, AFRL) 与美国国防部 (united states department of defense, DOD) 以及欧空局 (ESA) 等。日本宇宙科学研究所用 SVM 算法实现科学卫星姿态偏移不稳定性检测;巴西国家太空研究院 (instituto nacional de pesquisas espaciais, INPE) 结合数据仓库 OLAP 与数据挖掘提出分析架构,其根据趋势与相关性来诊断和检测卫星的早期异常;AFRL 与 DOD 开发了 STAR (satellite telemetry anomaly resolution) 工具实现对历史数据的分析,其基于推理以及网络预测方法检测与隔离异常;NASA 利用重力探测器监测数据进行拟合以实现短期数据分析,剔除局部异常,同时对中期数据分析其趋势性,并利用长期数据分析各部分数据关系。由此可见,遥测数据的分析工作已经引起世界范围内相关研究机构的广泛关注,尤其是通过遥测数据异常检测判断航天器设备的功能及性能状态更是成为国外相关研究机构关注的重点,遥测数据异常检测方法的应用情况如表6所示。

表6 国外遥测数据异常检测方法应用情况

Table 6 Application of anomaly detection methods for telemetry data in the main foreign related agents		
检测方法	应用情况	研究机构
近邻方法	Orca 工具 ^[42] ,成功用于地球观测卫星未知异常检测	美国航空航天局埃姆斯研究中心 (NASA ames research center)
	IMS ^[58-59] 工具,AMISS 软件(IMS 软件升级版),	
聚类方法	安装于 Johnson Space Center,实现对历史遥测参数正常模式的识别 离散化的聚类算法实现异常模式检测	日本东京大学
分类方法	利用 OCSVM 实现火箭监测数据异常发现	NASA Ames Research Center
预测方法	采用 DBN、核特征空间、RVM、PCA 及隐马尔科夫模型、	日本东京大学
	AR 进行遥测数据异常检测,2012~2013 年设计 ADAMS 平台, 并在日本宇宙科学研究所的 SD-4 试验星进行搭载验证	
密度方法	ARES 平台中的 Novelty Detection ^[36]	ESA 与欧洲空间控制中心
基于概率的异常数据	ARES 平台中的 DrMUST ^[35]	

在表 6 中,NASA Ames Research Center、日本东京大学及 ESA 近些年更是持续开展了面向航天器遥测数据的异常检测工作:NASA Ames Research Center 2003 年开发了 Orca^[42] 以及 IMS^[60] 工具,其中 Orca 是面向多元数据挖掘的工具,其通过计算相邻点之间的距离来挖掘异常以及离群点,而 IMS 工具采用聚类技术对状态监测的正常数据进行聚类,以识别后续异常数据,Orca 以及 IMS 工具已经成功应用于对地观测卫星的未知异常发现,之后 NASA 对 IMS 软件进行了升级,升级后的软件为 AMISS,而且 NASA 采用基于人工免疫系统的负选择算法开发了 MILD(multi-level immune learning detection)工具用于遥测参量异常检测,其研究进程如图 7 所示:



图 7 NASA 航天器遥测数据异常检测研究

Fig. 7 Anomaly detection of telemetry data in NASA

日本东京大学自 2004 年以来持续关注航天器遥测数据异常检测,其提出了利用相关向量自回归方法获取自适应阈值^[61]、利用 KPCA 法实现航天器异常检测^[62]、使用序列蒙特卡洛算法(sequential Monte Carlo)进行参数估计实现航天器故障诊断,使用混合概率主成分分析(mixture probabilistic principal component analysis, MPPCA)与隐半马尔科夫模型(hidden semi-Markov model, HSMM)实现航天器数据监测以及维度约简^[63]等,且日本东京大学将已经开发的方法设计为 ADAMS 平台^[64],实现了多元遥测数据的异常检测,并在日本宇宙科学研究所的 SD-4 试验星进行搭载验证,目前该平台还在验证中不断优化,其研究如图 8 所示。

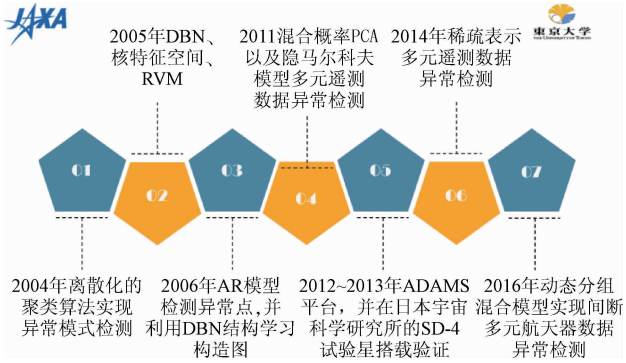


图 8 日本东京大学航天器遥测数据异常检测研究

Fig. 8 Anomaly detection research in the University of Tokyo
万方数据

欧洲太空局与欧洲空间控制中心开发的 ARES (Analysis and Reporting System) 平台用于离线数据分析^[65],其可用于挖掘相关数据的关系以及模式,尤其是其中的 DrMUST^[35] 以及 Novelty Detection^[36] 组件,DrMUST 是一个数据挖掘的客户端,其主要实现给定参数的模式匹配以及所有参数的相关分析,其中模式匹配部分可用于统计特定行为模式的发生情况,而相关分析可用于检测参数中可能存在的异常,相关性分析是基于统计特性的,其更健壮可靠。Novelty Detection 组件利用固定长度的统计特征(均值、标准差、最大值、最小值)来重新表示遥测数据,并结合广泛使用的 LOF (local outlier factor) 方法进行异常检测。

目前,可商用的国外遥测数据分析软件主要为 EPOCH,来自于 Integral Systems 公司,最新版为第四版,包含了在线分析以及离线分析组件,离线组件为 ABE (archive browser and extractor),隶属于 EPOCH IPSTM,可用于分析归档的实时数据来判断卫星以及地面系统的趋势与状态,其主要涉及的是一些基本的统计分析、呈现以及日志生成工作等。国际通信卫星组织经营的商用通信卫星系列采用了 Integral Systems 公司的 EPOCH IPS 软件来管理商用通信卫星 21 星以及 22 星。

4.2 国内遥测数据异常检测方法应用现状

国内对于航天器遥测数据分析关注较多的是航天院所以及与其有合作关系的公司和高校,如西安卫星测控中心通过遥测参数进行参数预测、故障诊断、异常突变检测,并对卫星健康状态进行评估;航天 502 所(北京控制工程研究所)对卫星推进系统进行故障诊断,并对传感器误差进行标定;航天东方红卫星则对参数的自动化监视、管理、判读进行研究;航天 501 所对在轨温度数据分析,并对健康进行评估、故障预警等;航天测控以及南京理工大学对遥测数据的可信度分析^[66]、预测^[67]开展研究;西北工业大学通过模型进行分类与知识表示^[68],并对之间的相关性进行分析^[69-70]。

而对于遥测数据异常检测,很多相关研究单位依据自身需求以及研究基础进行了异常检测算法的应用尝试,如表 7 所示。

除表 7 所述研究单位外,很多大学也通过与相关单位合作,开展了航天器遥测数据异常检测方法的应用研究,如东南大学提出利用自回归移动平均混合模型对某地球同步卫星控制太阳能帆板角度进行建模,通过精确的预测结果与实测遥测数据比较来发现异常^[31];海军工程大学与航天测控合作利用 LSSVM 对某卫星电源部件实现航天器遥测参量异常检测^[5];哈尔滨工业大学自动化测试与控制研究所从遥测数据自身特性出发,利用轨道幅角对遥测数据进行子序列划分,利用 LSSVM^[32] 以及 DTW^[33] 的 K 近邻实现了风云二、三号气象卫星温度、电压、

表 7 国内主要研究机构的遥测数据异常检测应用尝试

Table 7 Application research of anomaly detection for spacecraft telemetry data from some agents

异常检测算法	应用场景	研究机构
LSSVM 预测算法	太阳敏感器线路盒温度数据关联异常检测 ^[71]	西安卫星测控中心
基于 Kalman 滤波的预测算法	陀螺温度关联异常检测 ^[72]	航天东方红卫星
BP 神经网络	红外地球敏感器和动量轮相关遥测数据异常发现 ^[73]	
相似性方法	遥测数据片段异常检测 ^[74]	北京空间飞行器总体设计部
相关性分析	卫星电源系统单机参数与故障对应关系分析 ^[75]	航天测控
主成分分析方法	某卫星姿轨控分系统陀螺单机与单机上某点温度分析 ^[76]	上海卫星工程研究所
运用轨道积分器设定随时间实时变化的门限值	星间距离观测值异常剔除 ^[77]	中国科学院上海微小卫星工程中心

电流等遥测数据的异常片段检测,并利用高斯过程回归 (Gaussian process regression, GPR) 预测方法开展了流式数据的异常检测尝试^[78-79],以用于在线实现遥测数据异常模式发现^[80],哈尔滨工业大学深空探测基础研究中心提出了一种基于数据关联性分析的归纳式系统异常监测方法进行卫星飞轮异常检测^[81];西北工业大学提出将卫星姿态与传感器之间固有冗余关系是否保持作为判断故障类型的依据,利用 PCA 把这种关系通过测量空间的特征值进行量化,以监测特征值之间相应比例的变化实施判定^[82];南京航空航天大学结合灰色关联分析以及信息熵理论,提出一种能针对卫星数据进行异常模式挖掘的方法,实现 8 个月某卫星 57 维遥测数据的异常模式发现^[83]。

在国内实际应用的基于数据驱动的遥测数据异常检测方法多体现在遥测数据自动判读以及遥测数据处理软件中,如北京航天飞控中心自行研发的软件系统,其涉及遥测快速处理、信息快速监控和故障快速诊断 3 部分,将航天器下传的数据源码通过解码、辨识、曲线拟合以及分析计算等方式,快速转化成人们能够识别的参数信息。

4.3 航天器遥测数据异常检测应用现状分析

由以上两小节的分析可知,国外对于航天器遥测数据异常的关注较早,NASA、日本东京大学等都在 2003 年开始进行大量异常检测算法的尝试,而且到目前为止,已经开发了大量的可实用检测工具,用于真实探测卫星的异常事件发现,国外的公司更是以此为契机开发了可商用的遥测数据分析软件,但是从国外对遥测数据的持续关注也不难看出遥测数据异常检测算法仍处于大量算法直接应用阶段,并没有针对遥测数据特性进行算法的适应性改进,难免存在误检率高、算法的适应性差的问题;相对而言,国内对于遥测数据的异常关注较晚,基本在近几年内才有研究学者发表相关论文,目前尝试的算法较少,且只停留在实验室内验证阶段,没有形成研究体系,且不具备实际应用能力。由此可见,国内外在遥测数据异常检测的研究上差距较大,但是目前我国航天器遥测

数据的分析以及检测的需求强烈,与此相关的研究立项逐年增加,因此进行遥测数据异常检测研究是非常必要且急需的。

5 现有方法存在不足及未来展望

5.1 现有异常检测方法存在不足

航天器遥测数据按照时间序列采集与存储,属于时间序列,但是由于航天器本身的运行规律以及地面运行维护的高可靠性要求,该领域的发展还处于算法的尝试阶段,但是随着我国航天器发射数目以及密度提升,对于遥测数据异常检测的问题攻克刻不容缓。但是遥测数据其数据量大、专业性以及相关性强的特点使得其为工业大数据的典型应用领域,相较于互联网大数据(其重视分析及挖掘结果的相关性,而对于结果的逻辑性以及结果的可解释性要求低),遥测数据的检测更注重结果的物理意义以及结果之间关联性的机理逻辑。不同检测方法的性能特点总结如表 8 所示。

表 8 不同检测方法的性能特点

Table 8 Performance specialties of different detection methods

特性	误检率	漏检率	适应性	扩展性	可解释性	实时性
阈值	低	高	强	弱	好	好
专家系统	低	高	强	弱	好	差
专家经验模型	低	高	强	弱	好	好
数据驱动	高	低	弱	强	差	一般

由表 8 可知,虽然在阈值、专家经验、专家经验模型的基础上,基于数据驱动的方法已经凭借其无需专家经验、自动检测能力强以及强可扩展性成为研究热点以及未来大力投入的研究方向,但是依靠数据驱动的方法仅仅只能解决算法工具和模型的建立问题,目前的数据驱动方法对于航天器异常检测的应用存在明显不足,根据

表 8 所示,基于数据驱动的遥测数据异常检测方法不足如下。

1) 目前的研究采用纯数据驱动方法的检测,而航天器工作模式设定以及参数间关系复杂,导致检测算法误检率高,很难有效应用于实际的运管系统进行航天器的可靠性维护。

2) 大多数研究将异常检测方法直接应用于遥测数据异常检测领域,而忽略了遥测数据特性以及异常类型特点,算法结果的适应性以及可解释性差,因此很难有效指导后续的故障诊断以及维修。

3) 目前在线检测仪通过更新模型的方式实现,忽略航天器性能演化,实时性不足,模型自适应性差,很难在有效的时间内在线发现异常,导致故障的发现不及时,影响维护效果。

因此,高可靠的航天器运行要求以及工业大数据的分析场景,急需强时效性、低容错性以及可解释性的检测手段来挖掘隐匿在大量数据中的异常模式,实现数据到价值的最大转化。所以,需要研究学者在充分理解航天器特性的基础上,针对不同遥测数据中异常的表现形式,结合其不同特点,建立误检率低、检测效率高、解释性强的基于数据驱动的航天器遥测数据异常检测体系。

5.2 航天器遥测数据异常检测未来展望

根据本文对航天器遥测数据异常检测领域的方法及应用现状的调研及分析,并结合大数据、云计算等相关技术的发展,顺应工业 4.0、信息物理系统 CPS 以及中国制造 2025 的趋势,解析基于数据驱动的航天器遥测数据异常检测的未来发展趋势如下。

1) 基于模型与数据驱动的融合方法研究

采用纯数据驱动的方法进行建模时,会忽略已知专家经验以及航天器自身特性信息,造成先验经验的浪费,并且会使得算法受训练数据影响,造成误检率较高的情况,因此应有效地将专家经验以及数据驱动的方法进行结合,其表现在数据驱动方法的训练数据选择、模型参数构建以及决策阈值设定等多个方面,此种研究需要结合领域专家以及数据专家的共同努力,以建立误检率低、检测率高的融合方法。

2) 结合遥测数据特性分析的数据驱动建模方法研究

目前直接将时间序列异常检测方法用于遥测数据异常检测,会因为忽略遥测数据本身的特点,如局部周期性、长期趋势性以及不确定性等,造成算法的适应性差,因此在后续研究中,应在前期数据的分析以及特性划分方面增强研究,如遥测数据的变换域分析、统计特性分析以及时序特性分析等,充分建立遥测数据特性认知,以增强后续异常检测算法的针对性以及适应性,进而提高检测率。

3) 基于物理特性的遥测数据异常检测方法研究

基于数据驱动的方法,其在应用时会存在检测结果的可解释性差的问题,因此,在后续研究中,应重点结合遥测数据的物理特性,将其融入到遥测数据的异常检测步骤中,如采用基于轨道幅角划分的子序列异常检测方法,基于物理相关量关联性变化的上下文异常检测,基于工作模式量方向变化的多元异常检测等,通过物理特性与数据驱动方法结合,增强检测结果的逻辑性以及可解释性,此种方法的有效实施也需要相关技术人员与数据专家的配合以进行有效推进。

4) 基于流式数据的遥测数据异常检测

目前遥测数据的在线异常检测方法,虽然考虑到了遥测数据的在线到达以及模型更新特点,但是显然其忽略了历史遥测数据的过期现象以及航天器在轨性能退化的问题,因此模型的在线适应性较差,难以有效检测在线异常,后续研究中应该结合数据流异常检测算法的时间衰减以及数据演化特点,提升遥测数据异常检测的实时性以及准确性。

5) 建立完善的遥测数据异常检测评价体系

基于数据驱动的异常检测的评价主要采用检测率、误检率以及检测效率、ROC 曲线等衡量,但是显然对于异常检测的结果,能检测以及不能检测的评价太过绝对,很难有效评价算法的性能,如算法对噪声的敏感性、检测的提前以及延时特性等,所以需结合遥测数据的检测需求,建立多尺度、多层次的检测评价体系,以在不同的应用场合选择合适的算法,最大化检测结果的价值性。

6) 基于遥测大数据挖掘的异常检测

随着遥测数据量增长,采样率提升,待分析的遥测数据量呈膨胀式发展,大数据对应大价值,因此需借鉴大数据挖掘技术的发展实现遥测大数据中的异常发现,如采用 Hadoop 以及 HBase 等大数据存储及计算平台实现遥测数据存储及计算,并有效融合分布式挖掘、流式挖掘、可扩展挖掘技术及方法^[84],实现遥测大数据异常的快速、有效识别。

6 结 论

大量、关系复杂、专业性强的航天器遥测数据反映了设备的数据采集质量、性能退化以及故障信息等,已经成为航天领域增强其在轨可靠性的重要依据,得到国内外领域的广泛关注,并势必成为未来航天领域市场竞争以及运行管理能力强弱的重要争夺资源,但是其价值的体现需要突破传统数据异常检测以及分析的限制,重视遥测数据本身的特性以及其异常表现形式特点,在满足精度要求的情况下实现低容错率、强实时性以及可解释性的检测。

本文在异常检测领域总体介绍的基础上,结合对航

天领域遥测数据的认知,分析了航天器遥测数据异常检测的问题性质,涉及遥测数据性质、标签分布、异常检测输出形式、时效性以及异常类型等关键因素,并对其重点因素:遥测数据异常类型进行划分,有针对性地对于各类型遥测数据的异常检测方法、内涵以及其应用现状进行了详细阐述,从检测率、适应性、扩展性以及实时性等角度归纳总结了遥测数据异常检测方法的性能特点。并结合工业大数据的特点,分析了基于数据驱动的遥测数据异常检测存在的不足,展望了未来基于数据驱动的异常检测方法的发展方向。

通过本文对于航天器遥测数据异常检测领域的全面而细致的调研、分析以及解析,将为相关研究学者建立航天领域数据驱动的异常检测的整体概念,方便相关技术人员选择切实可行的检测方法,并为其研究工作提供重要依据及支撑,更重要的是扩展各研究单位的异常检测关注面,将航天领域异常检测问题与异常检测整体领域发展结合,借鉴互联网大数据分析及挖掘思路,为航天器遥测数据异常检测的研究提供新的突破点以及尝试方向,有效推进检测方法的应用进程。广大研究学者应在“数据即资源”的理念引导下,冷静分析,按照自身定位以及需求,广泛开展研究及合作,找到切实可行的研究方向,并通过分析遥测数据特性,建立持续的研究体系,以把握目前大量遥测数据带来的发展机遇,充分利用遥测数据创造大价值,在航天领域竞争中占领先机,增强地面运营管理能力,降低维护成本。

参考文献

[1] 程瑶. 基于模型的卫星姿控系统故障诊断[D]. 哈尔滨:哈尔滨工业大学, 2012:1-2.
CHENG Y. Model-based fault diagnosis for satellite attitude control system[D]. Harbin: Harbin Institute of Technology, 2012: 1-2.

[2] 陆智俊. 卫星故障诊断与维护专家系统的设计与实现[D]. 上海:复旦大学, 2010:1-2.
LU ZH J. Expert system design and realization for satellite fault diagnose and maintenance[D]. Shanghai: Fudan University, 2010:1-2.

[3] 中国产业信息网. 2015-2020 年中国卫星通信行业市场运行态势及投资前景分析预测报告[R]. 2015-06.
CNIL. Analysis and forecast of market operation situation and investment prospect of China's satellite communication industry in 2015-2020[R]. 2015-06.

[4] 谢础, 贾玉红, 黄俊, 等. 航空航天技术概论[M]. 2版. 北京:北京航空航天大学出版社, 2008:7-8.
XIE CH, JIA Y H, HUANG J, et al. Introduction to aerospace technology [M]. 2nd ed. Beijing: Beijing University of Aeronautics and Astronautics Press, 2008: 7-8.

[5] 陈冰, 鲁刚, 房红征, 等. 基于最小二乘支持向量机的卫星异常检测方法[J]. 计算机测量与控制, 2014, 22(3):690-692.
CHEN B, LU G, FANG H ZH, et al. Method of satellite anomaly detection based on least squares support vector machine[J]. Computer Measurement & Control, 2014, 22(3):690-692.

[6] CHEBOLI D. Anomaly detection of time series [J]. Dissertations & Theses, 2010: 37-47.

[7] CHANDOLA V, BANERJEE A, KUMAR V. Anomaly detection: A survey [J]. ACM Computing Surveys, 2009, 41(3):75-79.

[8] TAKEISHI N, YAIRI T. Anomaly detection from multivariate time-series with sparse representation [C]. IEEE International Conference on Systems, Man and Cybernetics, San Diego, CA, 2014: 2651-2656.

[9] HAWKINS D M. Identification of outliers [J]. Monographs on Applied Probability & Statistics, 1980, 80(2): 321-328.

[10] JOHNSON R. Applied multivariate statistical analysis [M]. Upper Saddle River: Prentice Hall/Pearson, 1992.

[11] BARNEET V, LEWIS T. Outliers in statistical data [M]. Chichester: John Wiley & Sons, 1994.

[12] KEOGH E, LIN J, LEE S H, et al. Finding the most unusual time series subsequence: algorithms and applications [J]. Knowledge & Information Systems, 2007, 11(1): 1-27.

[13] PIMENTEL M A F, CLIFTON D A, LEI C, et al. A review of novelty detection[J]. Signal Processing, 2014, 99(6):215-249.

[14] LI G, BRÄYSY O, JIANG L, et al. Finding time series discord based on bit representation clustering [J]. Knowledge-Based Systems, 2013, 54(4):243-254.

[15] MAIER W, STEINBACH E. A Probabilistic Appearance Representation and Its Application to Surprise Detection in Cognitive Robots [J]. IEEE Transactions on Autonomous Mental Development, 2010, 2(4): 267-281.

[16] LUND R, WANG X L, LU Q, et al. Change point detection in periodic and auto correlated time series[J]. Journal of Climate, 2007, 20(20):5178-5190.

[17] THATTE G, MITRA U, HEIDEMANN J. Parametric methods for anomaly detection in aggregate traffic [J]. IEEE/ACM Transactions on Networking, 2011, 19(2): 512-525.

[18] SULYKOS I, KECSKÉS-KOVÁCS K, CZIGLER I. Asymmetric effect of automatic deviant detection: The

- effect of familiarity in visual mismatch negativity [J]. Brain Research, 2015, 37(4):662-667.
- [19] YAIRI T, KAWSHARA Y, FUJIMAKI R, et al. Telemetry-mining: A machine learning approach to anomaly detection and fault diagnosis for space systems[C]. IEEE International Conference on Space Mission Challenges for Information Technology, 2006: 468-476.
- [20] HASHIMOTO M, NISHIGORI N, MIZUTANI M. Anomaly detective ground support system for mars probe NOZOMI[J]. Modern Fiction Studies, 2003, 49(2): 183-203.
- [21] KURIEN J, NAYAK P P. Back to the future for consistency-based trajectory tracking [C]. Seventeenth National Conference on Artificial Intelligence and Twelfth Conference on Innovative Applications of Artificial Intelligence, 2000: 370-377.
- [22] NARASIMHAN S, BROWNSTON L. HyDE - A general framework for stochastic and hybrid model-based diagnosis[J]. Proceedings 18th Interational. Workshop Principles Diagnosis DX-07, 2007: 162-169.
- [23] WILLIAMS B C, INGHAM M D, CHUNG S, et al. Model-based programming of fault-aware systems[J]. Ai Magazine, 2004, 24(4): 61-75.
- [24] TEAMS-RTWeb page [EB/OL]. <http://www.teamqsi.com/RT.html> [retrieved 26 April 2007].
- [25] RODONWeb page [EB/OL]. <http://www.uptimeworld.com/Rodon.aspx> [retrieved 19 May 2009].
- [26] SCHAEFER P, COLGREN R D, ABBOTT R J, et al. Technologies for reliable autonomous control (TRAC) of UAVs[C]. Digital Avionics Systems Conference, 2000: 1E3/1 - 1E3/7.
- [27] BARRETT A. Model compilation for real-time planning and diagnosis with feedback. [C]. Ijcai-05, Proceedings of the Nineteenth International Joint Conference on Artificial Intelligence, Edinburgh, 2005: 1195-1200.
- [28] 陈治佐, 刘兴钊, 吕高焕. Livingstone 用于航天器推进系统故障诊断[J]. 太赫兹科学与电子信息学报, 2013, 11(5):770-774.
CHEN ZH Z, LIU X ZH, LV G H. Fault diagnosis of spacecraft propulsion system by using Livingstone [J]. Journal of Terahertz Science and Electronic Information Technology, 2013, 11(5):770-774.
- [29] 黄成, 嵇辉, 车梦虎. 基于 TEAMS 和 IETM 的武器控制系统故障诊断与维修设备的设计[J]. 计算机测量与控制, 2014, 22(7):2131-2134.
HUANG CH, ZHUO H, CHE M H. Design of weapon control system's fault diagnosis and maintenance equipment based on TEAMS and IETM [J]. Computer Measurement & Control, 2014, 22(7):2131-2134.
- [30] YANG Y, HOU N. Data series forecasting and anomaly detection methods based on online least squares support vector machine [C]. Control Conference (CCC), 2013: 3597-3601.
- [31] 李维铮, 孟桥. 基于遥测数据动态特征的卫星异常检测方法[J]. 空间科学学报, 2014, 34(2):201-207.
LI W, MENG Q. Fault Detection for in-orbit Satellites Using an Adaptive Prediction Model[J]. Chinese Journal of Space Science, 2014, 34(2):201-207.
- [32] SONG AI G, LIANG J, LIU D T, et al. Anomaly detection of condition monitoring with predicted uncertainty for aerospace applications [C]. IEEE International Conference on Electronic Measurement & Instruments, 2015.
- [33] 陈静. 卫星遥测数据的时间序列相似性度量方法研究[D]. 哈尔滨:哈尔滨工业大学, 2015:39-43.
CHEN J. Similarity measure of time series for satellite telemetry data [D]. Harbin: Harbin Institute of Technology, 2015:39-43.
- [34] YAIRI T, OGASAWARA S, HORI K, et al. Summarization of spacecraft telemetry data by extracting significant temporal patterns [C]. Lecture Notes in Computer Science, 2004, 3056: 240-244.
- [35] MARTÍNEZ-HERAS J A, DONATI A, FISCHER A. DrMUST-a data mining approach for anomaly investigation [C]. SpaceOps 2012 Conference, Stockholm, Sweden, 2012: 1-6.
- [36] MARTÍNEZ-HERAS J A, DONATI A, KIRSCH M G F, et al. New telemetry monitoring paradigm with novelty detection[C]. SpaceOps 2012 Conference, Stockholm, Sweden, 2012: 1-9.
- [37] CHANDOLA V, CHEBOLI D, KUMAR V. Detecting anomalies in a time series database [R]. Technical Report, 2009.
- [38] 孙梅玉. 基于距离和密度的时间序列异常检测方法研究[J]. 计算机工程与应用, 2012, 48(20):11-17.
SUN Y M. Research on discords detect on time series based on distance and density [J]. Computer Engineering and Applications, 2012, 48(20):11-17.
- [39] TRUONG C D, ANH D T. An efficient method for motif and anomaly detection in time series based on clustering[J]. International Journal of Business Intelligence & Data Mining, 2015, 10(4): 356-377.
- [40] REN W W, HU L, ZHAO K, et al. An efficient parallel anomaly detection algorithm based on hierarchical clustering [J]. Journal of Networks, 2013, 8(3):

- 672-679.
- [41] QIAO Z, HE J, CAO J, et al. Multiple time series anomaly detection based on compression and correlation analysis: a medical surveillance case study [C]. Asia-Pacific International Conference on Web Technologies and Applications, 2012: 294-305.
 - [42] BAY S D, SCHWABACHER M. Mining distance-based outliers in near linear time with randomization and a simple pruning rule [C]. ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2003: 29-38.
 - [43] GritBot. RuleQuest Research [EB/OL], <http://www.rulequest.com> [retrieved 26 April 2007].
 - [44] IVERSON D L. Inductive system health monitoring [C]. International Conference on Artificial Intelligence, 2004: 605-611.
 - [45] IVERSON D L, MARTIN R, SCHWABACHER M, et al. General purpose data-driven system monitoring for space operations [J]. Journal of Aerospace Computing Information & Communication, 2012, 9(2): 26-44.
 - [46] AZEVEDO D R, AMBROSIO A M, VIEIRA M. Applying data mining for detecting anomalies in satellites [C]. European Dependable Computing Conference, 2012: 212-217.
 - [47] SCHWABACHER M, OZA N, MATTHEWS B. Unsupervised anomaly detection for liquid-fueled rocket propulsion health monitoring [J]. Journal of Aerospace Computing Information & Communication, 2009, 6(7): 464-482.
 - [48] MOHAMMAD B R, HUSSEIN W M. A novel approach of health monitoring and anomaly detection applied to spacecraft telemetry based on PLSDA multivariate latent technique [C]. International Workshop on Research and Education in Mechatronics, 2014: 1-6.
 - [49] Takeishi N, Yairi T, Nishimura N, et al. Dynamic grouped mixture models for intermittent multivariate sensor data [C]. Advances in Knowledge Discovery and Data Mining, 2016, 9652: 221-232.
 - [50] CHAN P K, MAHONEY M V. Modeling multiple time series for anomaly detection [C]. Fifth IEEE International Conference on Data Mining, 2005: 1550-4786.
 - [51] GEORGE A. Anomaly detection based on machine learning dimensionality reduction using pca and classification using SVM [J]. International Journal of Computer Applications, 2012, 47(21): 5-8.
 - [52] YAIRI T, INUI M, YOSHIKI A, et al. Spacecraft telemetry data monitoring by dimensionality reduction techniques [C]. SICE Annual Conference, 2010: 1230-1234.
 - [53] 李权, 周兴社. 基于 KPCA 的多变量时间序列数据异常检测方法研究 [J]. 计算机测量与控制, 2011, 19(4): 822-825.
 - LI Q, ZHOU X SH. Multivariate time series anomaly detection method based on KPCA [J]. Computer Measurement & Control, 2011, 19(4): 822-825.
 - [54] TSUYOSHI I, PAPADIMITRIOU S, VLACHOS M. Computing correlation anomaly scores using stochastic nearest neighbors [C]. IEEE International Conference on Data Mining, Omaha, NE, 2007: 523-528.
 - [55] QIU H, LIU Y, SUBRAHMANYA N A, et al. Granger causality for time-series anomaly detection [C]. IEEE 12th International Conference on Data Mining, 2012: 1074-1079.
 - [56] CHENG H, TAN P N, POTTER C, et al. Detection and characterization of anomalies in multivariate time series [J]. Food Microbiology, 2012, 30(1): 98-104.
 - [57] ELAD M. Sparse and redundant representations: from theory to applications in signal and image processing [M]. Berlin: Springer Publishing Company, 2010.
 - [58] IVERSON D L. Inductive system health monitoring [C]. International Conference on Artificial Intelligence, 2004: 605-611.
 - [59] IVERSON D L, MARTIN R, SCHWABACHER M, et al. General purpose data-driven system monitoring for space operations [J]. Journal of Aerospace Computing Information & Communication, 2012, 9(2): 26-44.
 - [60] IVERSON D. Data mining applications for space mission operations system health monitoring [C]. Proceedings of the SpaceOps 2008 Conference, ESA, EUMETSAT, AIAA, 2008: 1-8.
 - [61] FUJIMAKI R F, YAIRI T Y, MACHIDA K M. Adaptive limit-checking for spacecraft using relevance vector autoregressive model [J]. Proceedings of the 8th International Symposium on Artificial Intelligence, Robotics and Automation in Space-iSAIRAS', 2005: 1-7.
 - [62] FUJIMAKI R, YAIRI T, MACHIDA K. An approach to spacecraft anomaly detection problem using kernel feature space [C]. 11th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2005: 401-410.
 - [63] TAGAWA T, YAIRI T, TAKATA N, et al. Data monitoring of spacecraft using mixture probabilistic principal component analysis and hidden Semi-Markov

- models [C]. Data Mining and Intelligent Information Technology Applications (ICMiA), 2011: 141-144.
- [64] YAIRI T, ODA T, NAKAJIMA Y, et al. Evaluation testing of learning-based telemetry monitoring and anomaly detection system in SDS-4 operation [C]. The International Symposium on Artificial Intelligence, Robotics and Automation in Space (i-SAIRAS), 2014: 1-10.
- [65] RUI S. How the use of "Big Data" clusters improves off-line data analysis and operations [C]. International Conference on Space Operations, 2014: 1-8.
- [66] FANG H, MA H, HAN L, et al. The study of the spacecraft telemetry data credibility calculation method based on the probability statistics and fuzzy algorithm [J]. National Conference on Information Technology and Computer Science (CITCS 2012), 2012: 628-631.
- [67] FANG H Z, ZOU K X, YI D W, et al. The study of spacecraft telemetry data prediction based-on SERTS model [C]. Prognostics and System Health Management Conference, 2011: 1-5.
- [68] WU T, SUN D, YU T. Knowledge representation method for spacecraft health status telemetry monitoring [C]. International Conference on Quality, Reliability, Risk, Maintenance, and Safety Engineering, 2013: 1771-1773.
- [69] 赵红毅, 任国恒. ID3 算法在卫星遥测数据分析中的应用 [J]. 西安工业大学学报, 2010, 30(5): 491-494.
- ZHAO H Y, REN G H. Application of ID3 algorithm in the analysis of satellite telemetry data [J]. Journal of Xi'an Technological University, 2010, 30(5): 491-494.
- [70] 刘海泉, 罗钧旻, 杨盛泉. 航天器遥测数据的自相似研究 [J]. 西安工业大学学报, 2013, 33(3): 193-197.
- LIU H Q, LUO J Y, YANG SH Q. Research on self-similarity of spacecraft telemetry data [J]. Journal of Xi'an Technological University, 2013, 33(3): 193-197.
- [71] 张栋, 胡绍林, 于宁莉, 等. 航天器下行数据异变检测算法研究 [J]. 飞行器测控学报, 2013, 32(2): 123-126.
- ZHANG D, HU SH L, YU N L, et al. Anomaly data detection algorithm for telemetry of spacecraft [J]. Journal of Spacecraft TT&C Technology, 2013, 32(2): 123-126.
- [72] 吴婧, 苏振华, 孙诚. 一种基于 Kalman 滤波的卫星遥测数据判读系统 [J]. 航天器工程, 2014, 23(3): 86-91.
- WU J, SU ZH H, SUN CH. Satellite telemetry data interpretation system based on Kalman filter [J]. Spacecraft Engineering, 2014, 23(03): 86-91.
- [73] 苏振华, 陆文高, 齐晶, 等. 基于 BP 神经网络的卫星故障诊断方法 [J]. 计算机测量与控制, 2016, 24(5): 63-66.
- SU Z H, LU W G, QI J, et al. A method of satellite fault diagnosis based on BP neural network [J]. Computer Measurement & Control, 2016, 24(5): 63-66.
- [74] 张雷, 孙波, 罗荣蒸, 等. 一种基于遥测数据的卫星异常状态检测系统, CN103646167A [P]. 2014-03-19.
- ZHENG L, SUN B, LUO R ZH, et al. Abnormal detection system of satellite based on telemetry data, CN103646167A [P]. 2014-03-19.
- [75] 李蕊, 房红征, 罗凯. 一种航天器运行异常状态的分析方法及装置, CN103699118A [P]. 2014-04-02.
- LI R. FANG H ZH. LUO K. Analysis method and device of abnormal operation state for spacecraft, CN103699118A [P]. 2014-04-02.
- [76] 钱威, 周军, 张国勇, 等. 基于主成分分析的卫星遥测回归方法, CN105590026A [P]. 2016-05-18.
- QIAN W, ZHOU J, ZHANG G Y, et al. Satellite telemetry regression based on principal component analysis, CN105590026A [P]. 2016-05-18.
- [77] 郝占炯, 王毅, 尚琳, 等. 基于星间测距的卫星自主导航中异常值剔除方法 [J]. 遥测遥控, 2010, 31(4): 11-15.
- HAO ZH J, WANG Y, SHANG L, et al. Method of abnormal value rejection in satellite autonomous navigation based on cross-link range [J]. Journal of Telemetry, Tracking and Command, 2010, 31(4): 11-15.
- [78] PANG J, LIU D, PENG Y, et al. Detecting Continual Anomalies in Monitoring Data Stream Based on Sampling Gaussian Process Regression [C]. IEEE International Conference on Prognostics and Health Management, 2015.
- [79] PANG J, LIU D, LIAO H, et al. Anomaly detection based on data stream monitoring and prediction with improved Gaussian process regression algorithm [C]. Prognostics and Health Management, IEEE, 2015: 1-7.
- [80] 庞景月. 滑动窗口模型下的数据流自适应异常检测方法研究 [D]. 哈尔滨: 哈尔滨工业大学, 2013.
- PANG J Y. Adaptive anomaly detection for data stream of sequence-based sliding windows model [D]. Harbin: Harbin Institute of Technology, 2013.
- [81] 龚学兵, 王日新, 徐敏强. 基于数据关联性分析的飞轮异常检测 [J]. 航空学报, 2015, 36(3): 898-906.
- GONG X B, WANG R X, XU M Q. Abnormality detection for flywheels based on data association

analysis[J]. Acta Aeronautica et Astronautica Sinica, 2015, 36(3):898-906.

- [82] 李楠, 张云燕, 李言俊. 一种自旋稳定卫星姿态传感器数据异常的诊断方法[J]. 宇航学报, 2011, 32(6): 1327-1332.

LI N, ZHANG Y Y, LI Y J. A diagnosis algorithm for abnormal data of spin-stabilized satellite attitude sensors[J]. Journal of Astronautics, 2011, 32(6): 1327-1332.

- [83] 徐宇航, 皮德常. 卫星异常模式挖掘方法[J]. 小型微型计算机系统, 2015, 36(9):1988-1992.

XU Y H, PI D CH. Method to mine satellite abnormal patterns[J]. Journal of Chinese Computer Systems, 2015, 36(9):1988-1992.

- [84] 彭宇, 庞景月, 刘大同, 等. 大数据:内涵、技术体系与展望[J]. 电子测量与仪器学报, 2015, 29(4): 469-482.

PENG Y, PANG J Y, LIU D T, et al. Big data: Connotation, technical framework and its development[J]. Journal Of Electronic Measurement And Instrumentation, 2015, 29(4):469-482.

作者简介



彭喜元, 工学博士、教授、博士生导师, 1980年至1992年就读于哈尔滨工业大学无线电工程系, 先后获学士、硕士、博士学位。主要研究方向是自动测试理论、技术及系统, 先进故障诊断技术及应用。

E-mail: pxy@hit.edu.cn

Peng Xiyuan, he is now a professor and Ph. D candidate supervisor in the Major of Instrumentation Science and Technology, Harbin Institute of Technology (HIT). From 1980 to 1992, he studied in Department of Radio Engineering of Harbin Institute of Technology where he received his B. S., M. S. and Ph. D successively. His main research fields include automatic testing theory, technology and system, advanced fault diagnosis technology and its application.



庞景月, 工学在读博士, 2011年于重庆理工大学获得学士学位, 2013年于哈尔滨工业大学获得硕士学位, 目前在哈尔滨工业大学攻读博士学位。主要研究方向为信息处理、故障预测与健康管理、数据流异常检测与挖掘。

E-mail: jypang@hit.edu.cn

Pang Jingyue, Ph. D candidate. She received the B. S. from Chongqing University of Technology in 2011, and received M. S. from Harbin Institute of Technology in 2013. Now she is a Ph. D candidate in Harbin Institute of Technology, her research interests are information processing, prognostics and health management, abnormal detection and mining for data stream.



彭宇(通讯作者), 工学博士、教授、博士生导师, 分别于1996年、1998年与2004年在哈尔滨工业大学获得学士、硕士以及博士学位。主要研究方向为虚拟仪器和自动测试、故障预测与健康管理、可重构计算等。

E-mail: pengyu@hit.edu.cn

Peng Yu (Corresponding author) is now a professor and Ph. D candidate supervisor in the Major of Instrumentation Science and Technology, Harbin Institute of Technology. He received his B. S., M. S. and Ph. D in 1996, 1998 and 2004 respectively from Harbin Institute of Technology. His main research fields include virtual instruments and automatic test technologies, prognostics and system health management, and reconfigurable computing, etc.



刘大同, 工学博士、副教授、硕士生导师, 1999年至2010年就读于哈尔滨工业大学, 先后获学士、硕士、博士学位, 主要研究方向为自动测试技术、智能测试信息处理、故障预测和健康管理。

E-mail: liudatong@hit.edu.cn

Liu Datong, male. He is now an associate professor and Master candidate supervisor in the Major of Instrumentation Science and Technology, Harbin Institute of Technology. From 1999 to 2010, he received his B. S., M. S. and Ph. D successively from Harbin Institute of Technology. His research interests include automatic test technologies, intelligent test data processing, and prognostics and health management.